Hands-on Deep Learning - Aula 4

Redes Neurais Recorrentes

Camila Laranjeira[1], Hugo Oliveira[12], Keiller Nogueira[12]

[1]Programa de Pós-Graduação em Ciência da Computação (PPGCC)
Universidade Federal de Minas Gerais

[2]Interest Group in Pattern Recognition and Earth Observation (PATREO)
Universidade Federal de Minas Gerais

18 de Agosto, 2018

DCC
DEPARTAMENTO DE
CIÊNCIA DA COMPUTAÇÃO

UFMG

Agenda

Agenda

Intuição

- Em qual direção a bola está indo?

tempo = 4

Intuição

- Em qual direção a bola está indo?

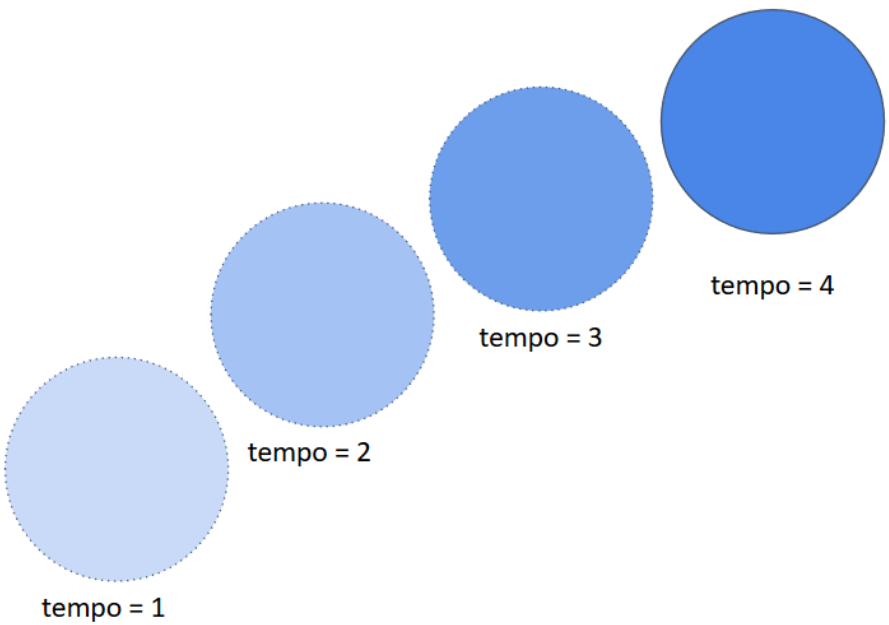

Sequências

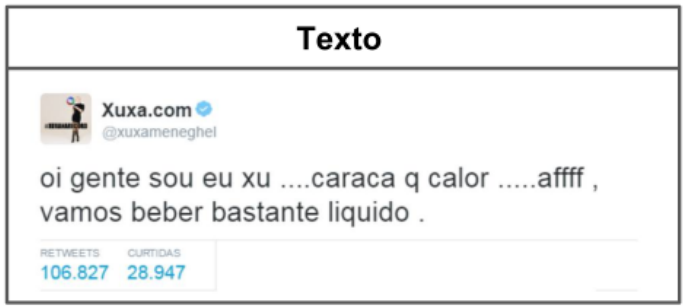

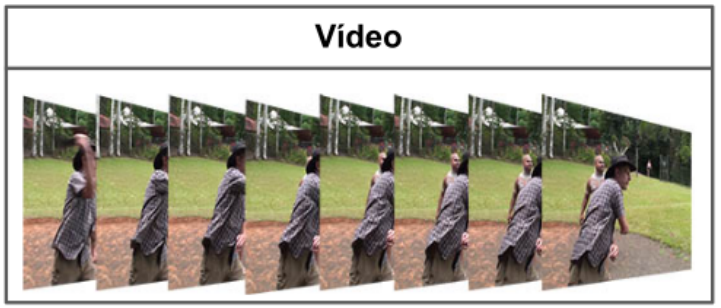

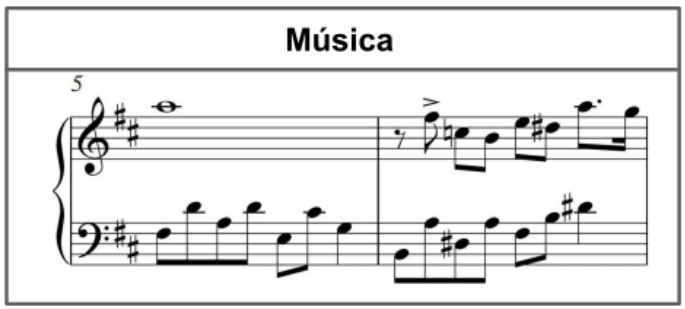

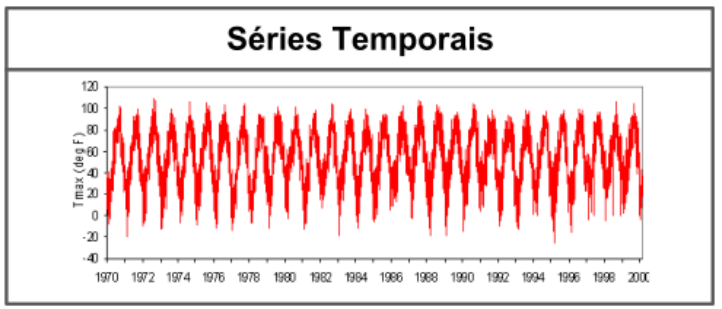

- Eventos relacionados entre si.
- Ordem dos eventos é um fator relevante.

Memória de sequências

- Experimente listar esse conjunto de eventos fora da ordem (de trás pra frente por exemplo):
  - Alfabeto
  - Letras de música
  - Consegue pensar em outro exemplo?

Memória de sequências

- Experimente listar esse conjunto de eventos fora da ordem (de trás pra frente por exemplo):
  - Alfabeto
  - Letras de música
  - Número de telefone
  - CPF
  - Senhas
  - etc...
- A memória de sequência é condicional. Elementos não são memorizados individualmente, registramos a organização entre eles.

MLP para Sequências

- Vamos tentar modelar um problema de sequência com uma MLP
- *Sequence tagging* / *Sequence labeling*
  - Dado uma sequência de palavras, rotule cada uma das palavras de acordo com a sua categoria gramatical
  - Exemplo 1:
    $X = \{$ Nós, fizemos, um, **acordo** $\}$,
    $Y = \{$ Pronome, verbo, artigo indefinido, **substantivo** $\}$
  - Exemplo 2:
    $X = \{$ Eu, **acordo**, cedo $\}$,
    $Y = \{$ Pronome, **verbo**, advérbio $\}$

MLP para sequência

- Modelando a entrada

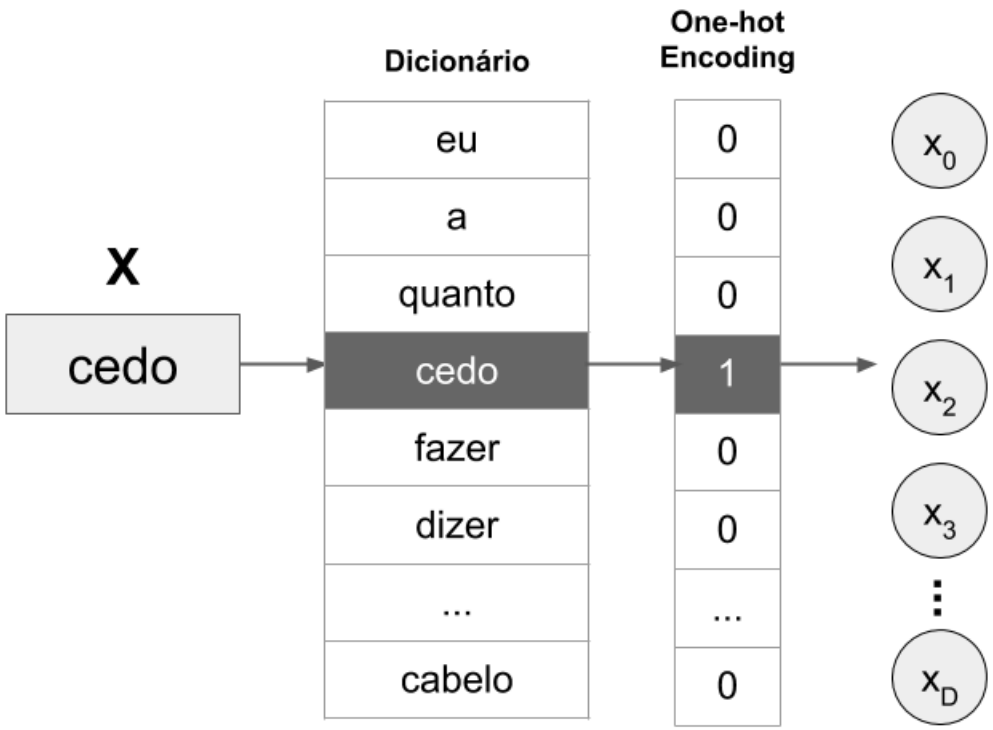

MLP para sequência

- Modelando a saída

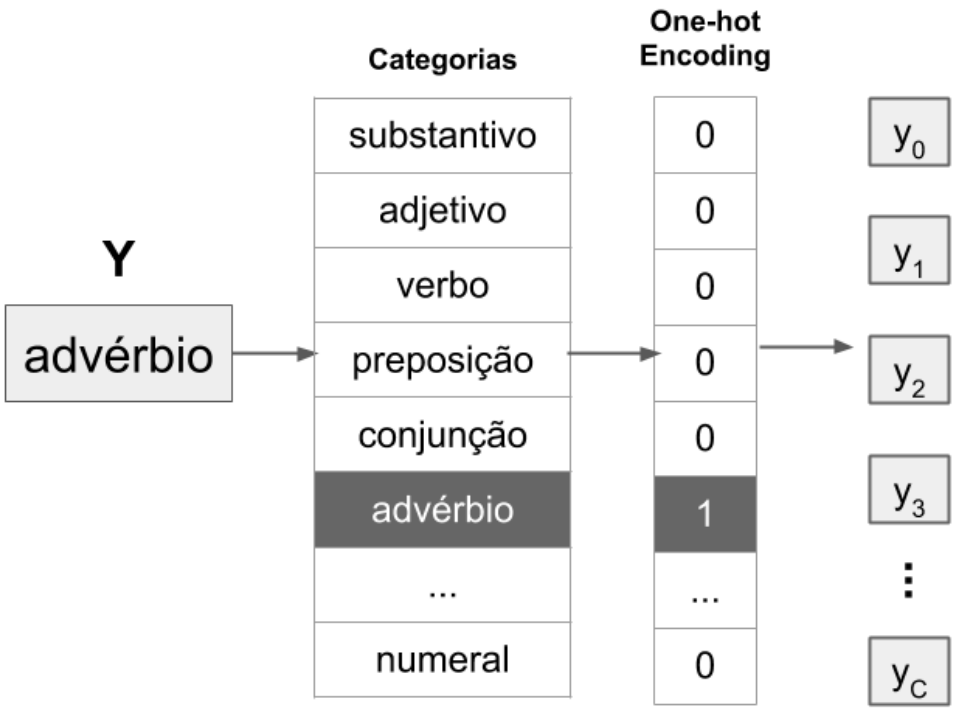

MLP para sequência

- Modelando o MLP que categoriza palavras gramaticalmente (para uma palavra)

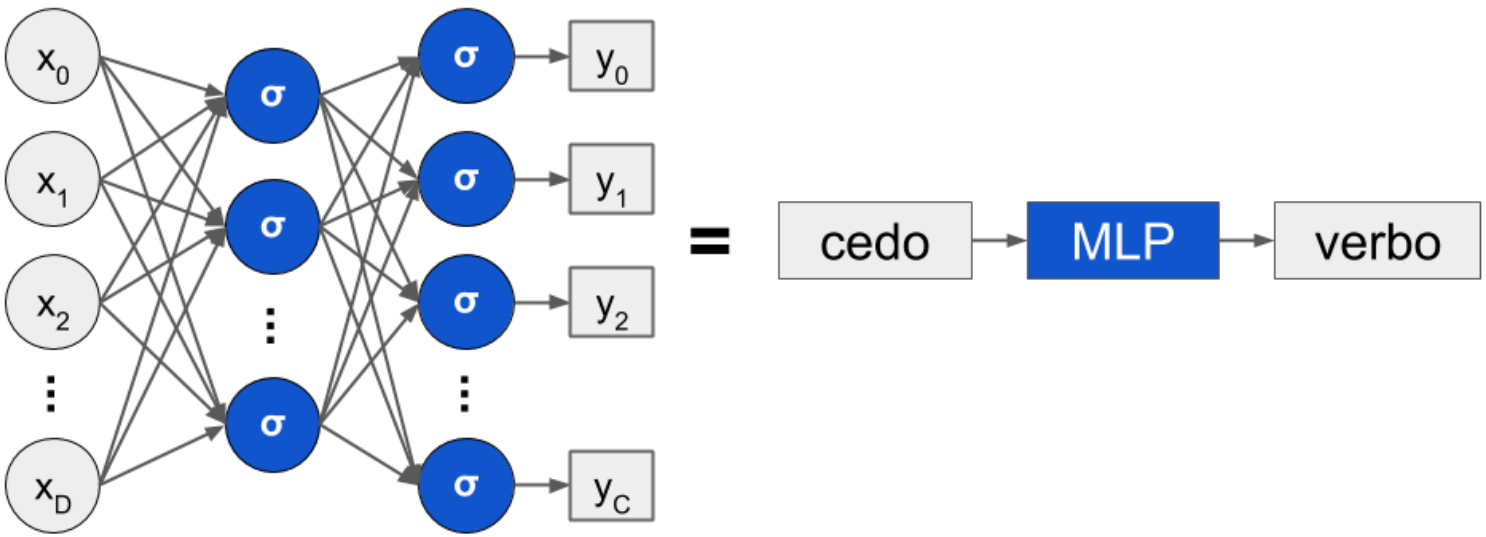

MLP para sequência

- Modelando o MLP que categoriza palavras gramaticalmente (para uma **sequência** de palavras)

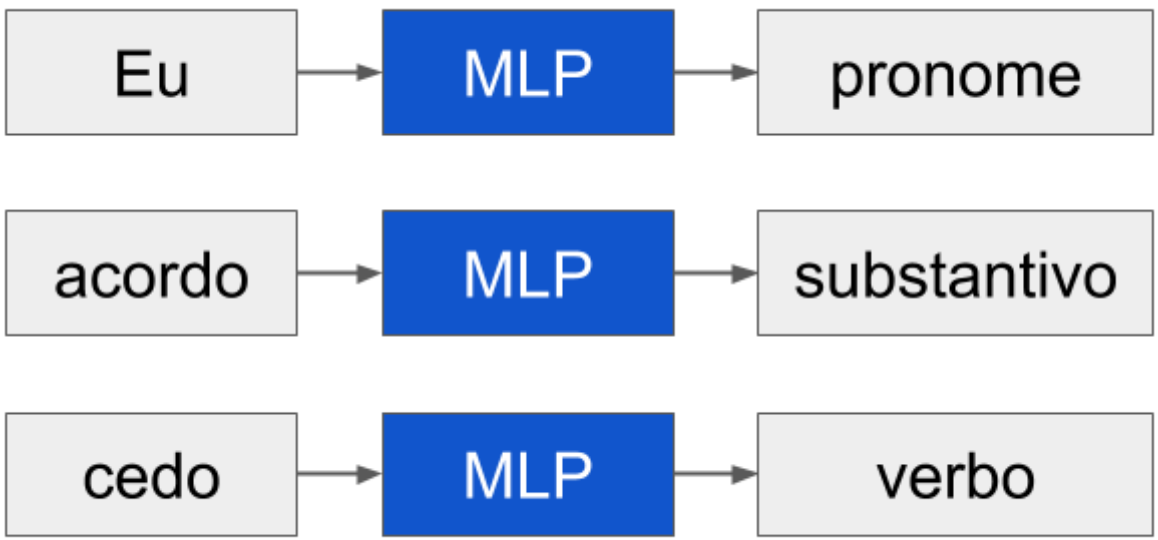

MLP para Sequências

- Limitações dessa modelagem:
  - O modelo não incorpora a **relação entre palavras**, já que recebe uma entrada de cada vez e atualiza seus pesos de acordo com a informação individual de cada palavra.

MLP para Sequências

- Vamos tentar mais uma abordagem...

MLP para Sequências

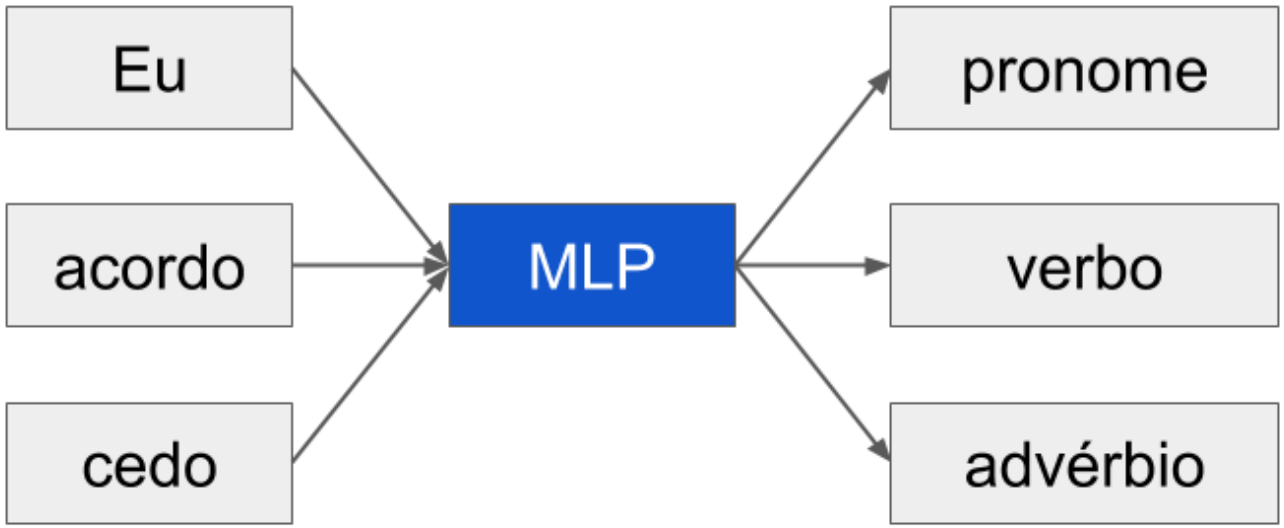

- Tratamos a sequência de entrada como um único dado
- A sequência de saída também é um único vetor

MLP para Sequências

- Limitações dessa modelagem:
  - Input e output precisam ter tamanho fixo. Problemas do mundo real envolvem sequências de tamanho variável.
  - Saídas complexas como essa caem no problema intitulado "Predição estruturada" [1].
    - Trata-se de um problema muito difícil de otimizar.

[1] Linguistic Structure Prediction by Noah A. Smith http://www.cs.cmu.edu/ nasmith/LSP/

MLP para Sequências

- Última tentativa!

MLP para Sequências

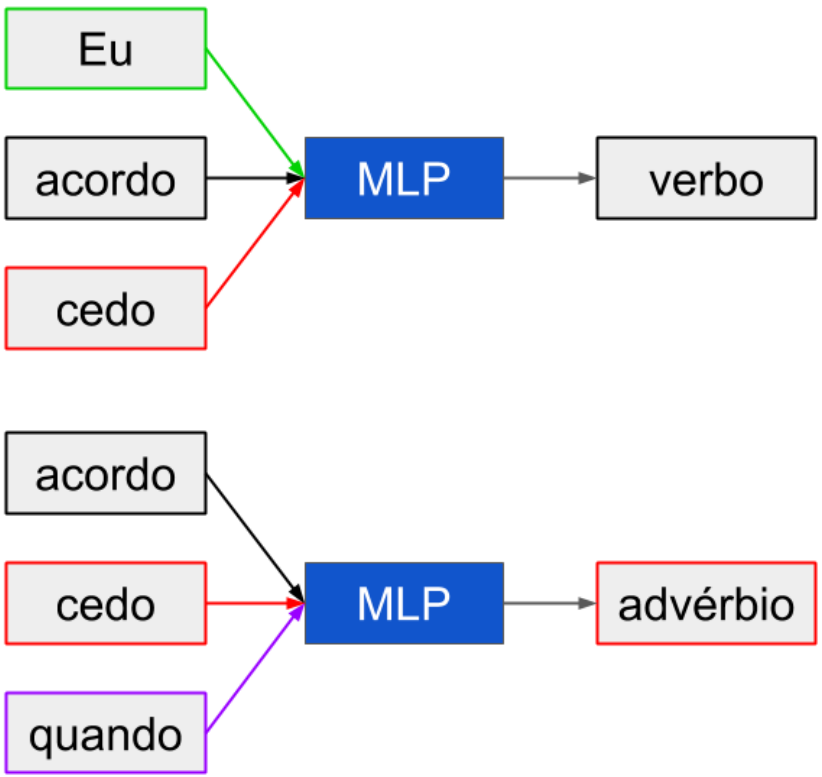

- Define-se uma janela de tamanho w
- Saídas são geradas individualmente em função de uma parte da sequência.

MLP para Sequências

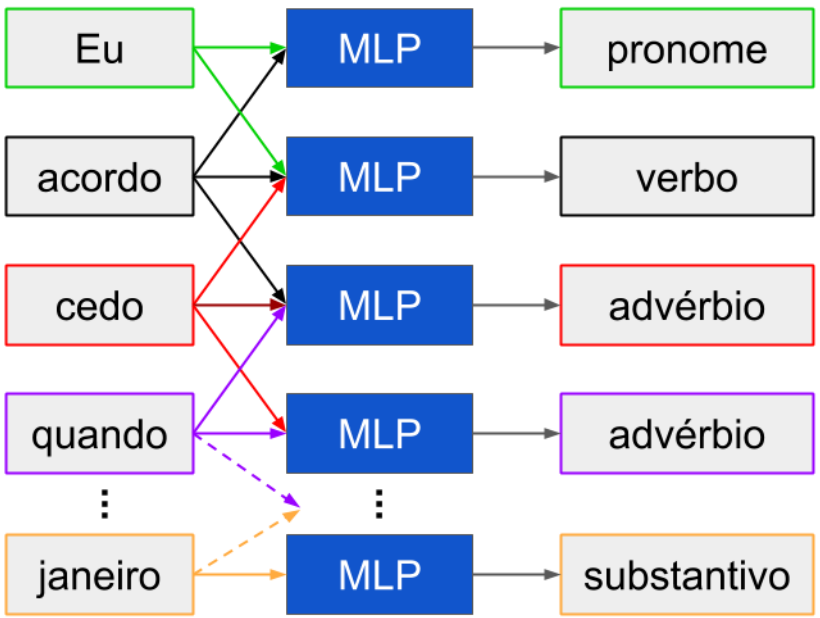

- Define-se uma janela de tamanho w
- Saídas são geradas individualmente em função de uma parte da sequência.

MLP para Sequências

- Essa modelagem é utilizado para modelos de linguagem *n-gram*
- *n-gram* - Sequência contínua de *n* items dado um texto (Palavras, sílabas, letras, etc.)

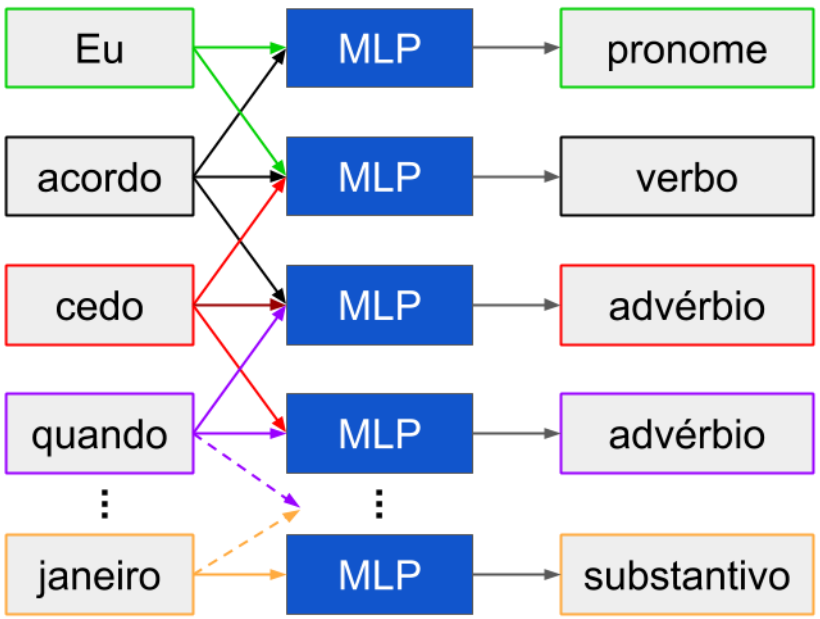

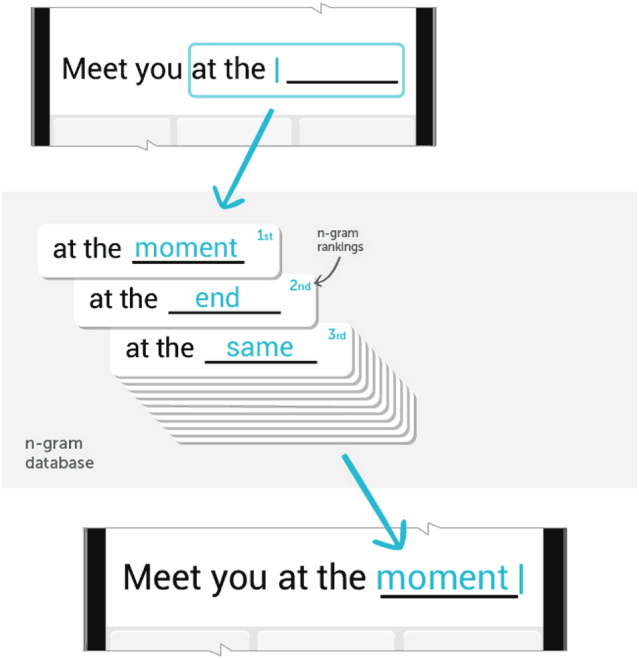

MLP para Sequências

- Limitações dessa modelagem:
  - Uma janela fixa pode não atender bem todos os casos (algumas palavras podem exigir um contexto maior)
    - Dependências de longo prazo podem ser perdidas

Limitações de Feed-Forward Networks

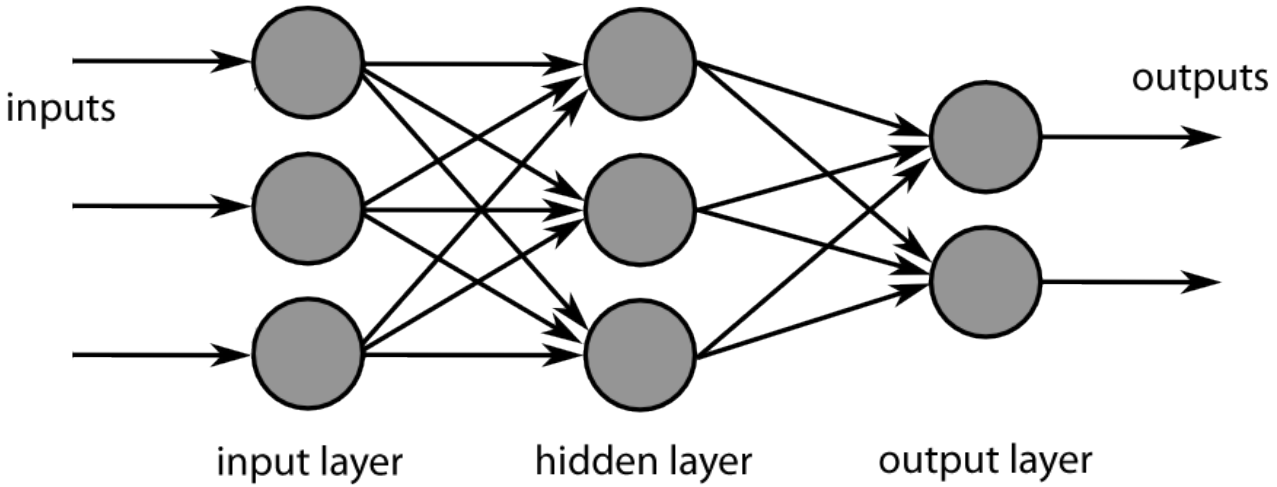

- Em resumo, as redes "feed-forward"apresentam limitações para lidar com sequências
- Em grande parte essas limitações estão associadas com a incapacidade de guardar memória das instâncias anteriores

Redes Neurais Recorrentes

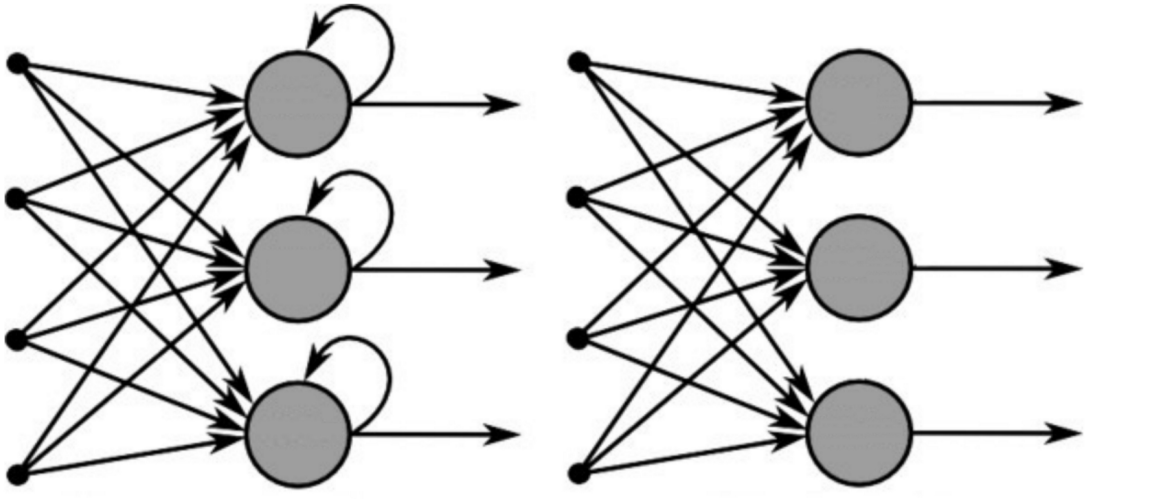

Recurrent Neural Network Feed-Forward Neural Network

- Diferente de unidades da Feed-Forward Network, unidades recorrentes guardam seu próprio estado, compondo uma memória interna.

Redes Neurais Recorrentes

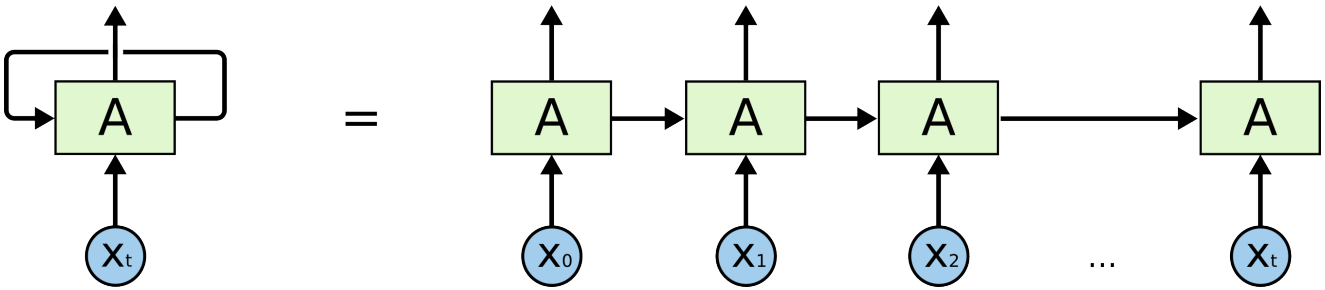

- Cada entrada x_t gera um estado que é retroalimentado para a unidade recorrente, permitindo que a informação do passado persista.
- Essa arquitetura permite lidar com **sequências de tamanhos variáveis.**

Redes Neurais Recorrentes

- Essa arquitetura permite lidar com sequências de tamanhos variáveis.
  - Ponto para o Pytorch! Outros frameworks (de grafos estáticos) exigem que você fixe o tamanho da sequência quando instancia a rede.

Redes Neurais Recorrentes

- Essa arquitetura permite lidar com sequências de tamanhos variáveis.
  - Ponto para o Pytorch! Outros frameworks (de grafos estáticos) exigem que você fixe o tamanho da sequência quando instancia a rede.
  - Tensorflow 2.0 suporta grafos dinâmicos!

Figura: https://blog.exxactcorp.com/tensorflow-2-0-dynamic-readable-and-highly-extended/

Agenda

Multi-Layer Perceptron - MLP

- $x \rightarrow y$
- $y = f(x)$
- $y = \sigma(W_{xy}x + b)$

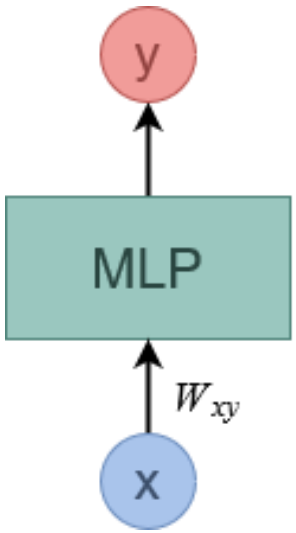

Unidade Recorrente (*Vanilla*)

- $x \rightarrow y$
- $y = f(x)$
- $y = \sigma(W_{xy}x + b)$

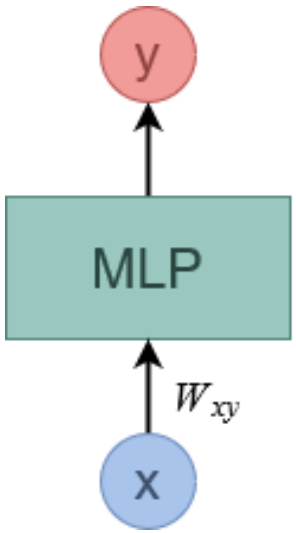

- $x_t \rightarrow h_t$
- $h_t = f(h_{t-1}, x_t)$
- $h_t = \sigma(W_{xh}x_t + W_{hh}h_{t-1} + b)$

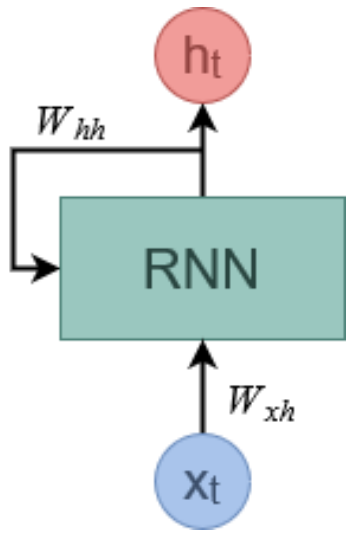

Unidade Recorrente (*Vanilla*)

- Cada entrada x_t gera um **estado** h_t (*hidden state*) que é retroalimentado para a unidade recorrente, permitindo que a informação do passado persista.

- $x_t \rightarrow h_t$
- $h_t = f(h_{t-1}, x_t)$
- $h_t = \sigma(W_{xh}x_t + W_{hh}h_{t-1} + b)$

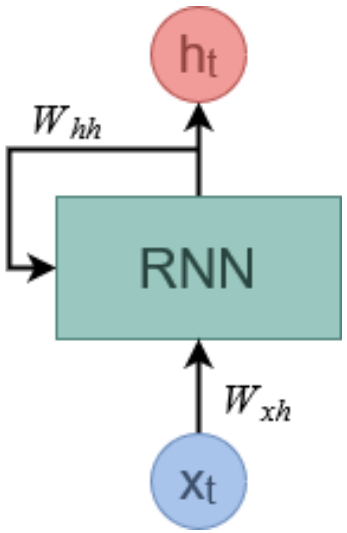

Unidade Recorrente (*Vanilla*)

- $x_t \rightarrow h_t$
- $h_t = f(h_{t-1}, x_t)$
- $h_t = \sigma(W_{xh}x_t + W_{hh}h_{t-1} + b)$

- Parâmetros Otimizáveis
  - W_{xh} - *input to hidden*
  - W_{hh} - *hidden to hidden*
  - b - *bias*

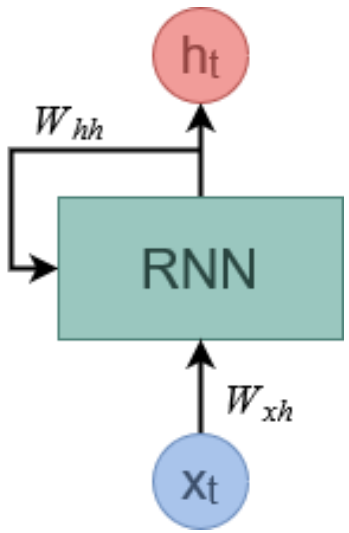

Unidade Recorrente (*Vanilla*)

- Representação "desenrolada"

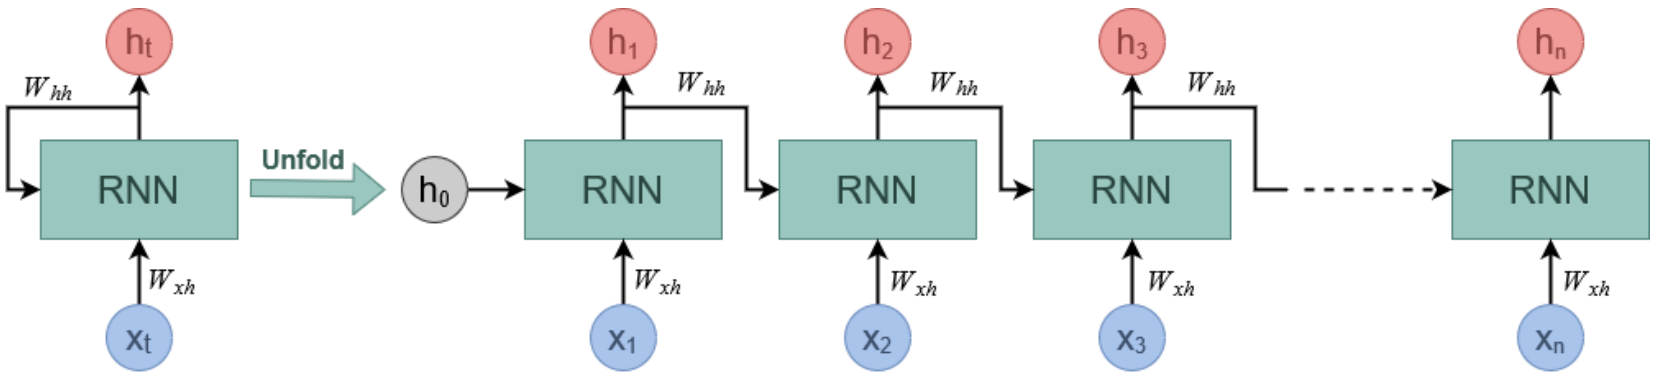

- A memória da rede recorrente persiste ao longo do tempo, ou seja, o **estado** h_t acumula conhecimento dos seus predecessores $\{h_{t-1}, h_{t-2}, \ldots, h_1\}$.

Unidade Recorrente (*Vanilla*)

- Representação "desenrolada"

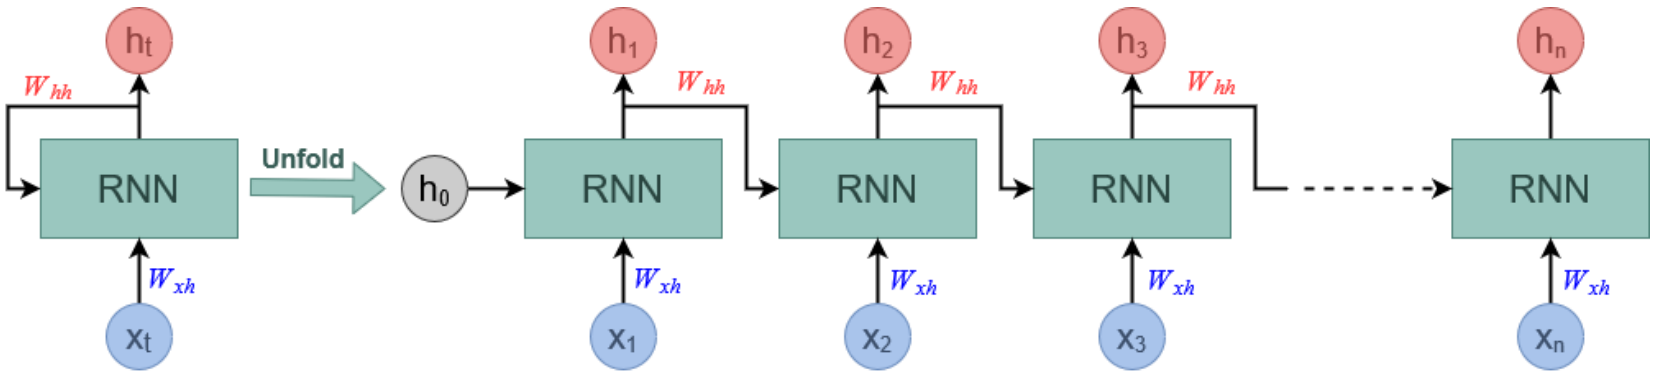

- **O processamento de uma sequência é iterativo!**
- Os pesos W_{xh} e W_{hh} são os mesmos ao longo de todo o processamento da sequência.

Unidade Recorrente (*Vanilla*)

- **O processamento de uma sequência é iterativo!**

In [ ]:
```
class RNN():
    ...

    def step(x):
        self.hidden = np.tanh( np.dot(self.W_hh, self.hidden) +
                               np.dot(self.W_xh, x) + b_h)
        y = sigm( np.dot(self.W_hy, self.hidden) + b_y )

        return y

    def forward(input_data):

        output = []
        for x in input_data:
            output.append(self.step(x))
```

Unidade Recorrente (*Vanilla*)

- Representação "desenrolada"

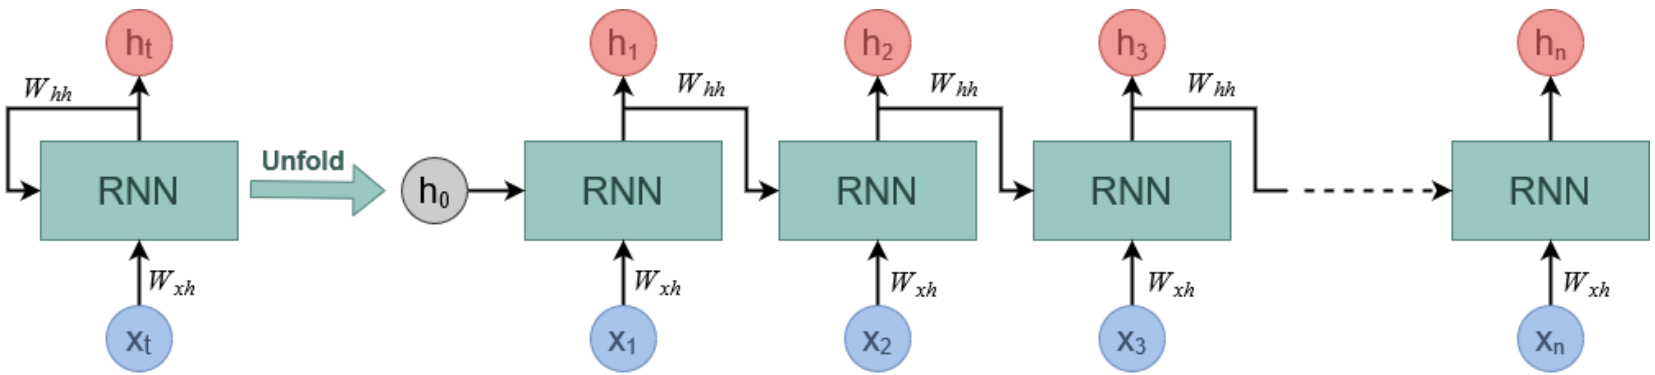

- Sendo a função recorrente $f(x_t, h_{t-1})$ dependente do estado anterior, no tempo $t = 1$ **é preciso inicializar o estado inicial** h_0.

Unidade Recorrente (*Vanilla*)

- Sendo a função recorrente $f(x_t)$ dependente do estado h_{t-1}, no tempo $t = 1$ **é preciso inicializar o estado inicial** h_0.

In [ ]:
```
class RNN():
    ...

    def step(x):
        self.hidden = np.tanh( np.dot(self.W_hh, self.hidden) +
                               np.dot(self.W_xh, x) + b_h)
        y = sigm( np.dot(self.W_hy, self.hidden) + b_y )

        return y

    def forward(input_data):

        self.hidden = np.zeros(self.batch_size, self.hidden_size)

        # input_data.size() = (seq_len, batch_size, input_size)
        output = []
        for x in input_data:
            output.append(self.step(x))
```

Demo

Forward Recorrente do Zero

RNN_Forward.py

RNNCell no Pytorch

- RNNCell (torch.nn.RNNCell)
  - input_size: Número de features da entrada
  - hidden_size: Número de features no *hidden state*

In [ ]:
```
class RNN():
    def init(self, input_size, hidden_size):
        self.rnn = torch.nn.RNNCell(input_size, hidden_size)

    def forward(input_data):
        # Set initial hidden and cell states
        self.hidden = Variable(torch.zeros(batch_size, hidden_size))

        for x in input_data:
            self.hidden = self.rnn(x, self.hidden)
```

Demo

Forward Recorrente do Zero

RNN_Forward.py

Deep Learning com RNN

- Assim como redes convolucionais extraem features de imagem com as camadas convolucionais e realizam inferência com camadas lineares...

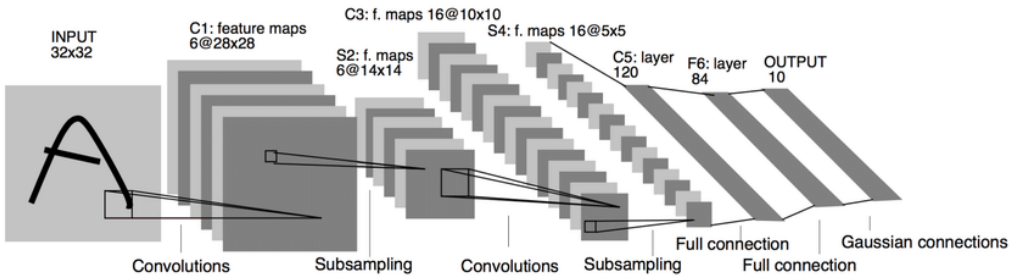

Deep Learning com RNN

- Assim como redes convolucionais podem extrair features de imagem com as camadas convolucionais e realizar inferência com camadas lineares, **também podemos fazer isso com redes recorrentes**.

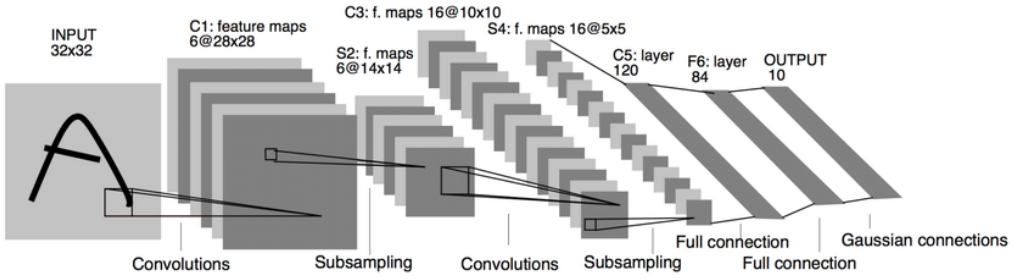

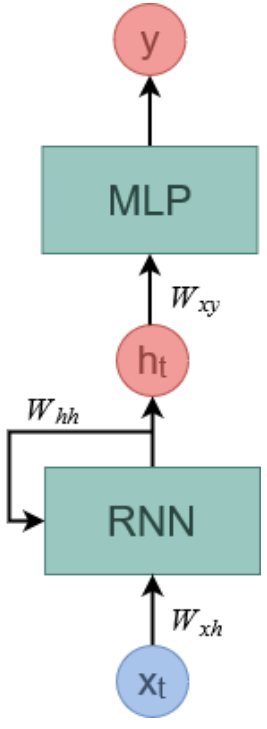

Deep Learning com RNN

- Assim como redes convolucionais podem extrair features de imagem com as camadas convolucionais e realizar inferência com camadas lineares, também podemos fazer isso com redes recorrentes.

- Consideramos a saída da RNN como uma **feature temporal**.

- A camada linear realiza a inferência de y (regressão, classificação, etc.) a partir do **hidden state** h_t.

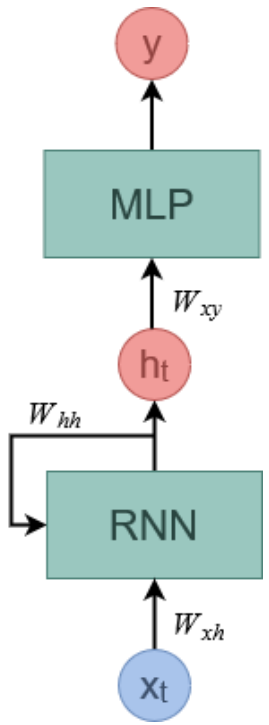

Taxonomia dos Problemas

- A inferência realizada por um modelo recorrente pode variar das seguintes formas.

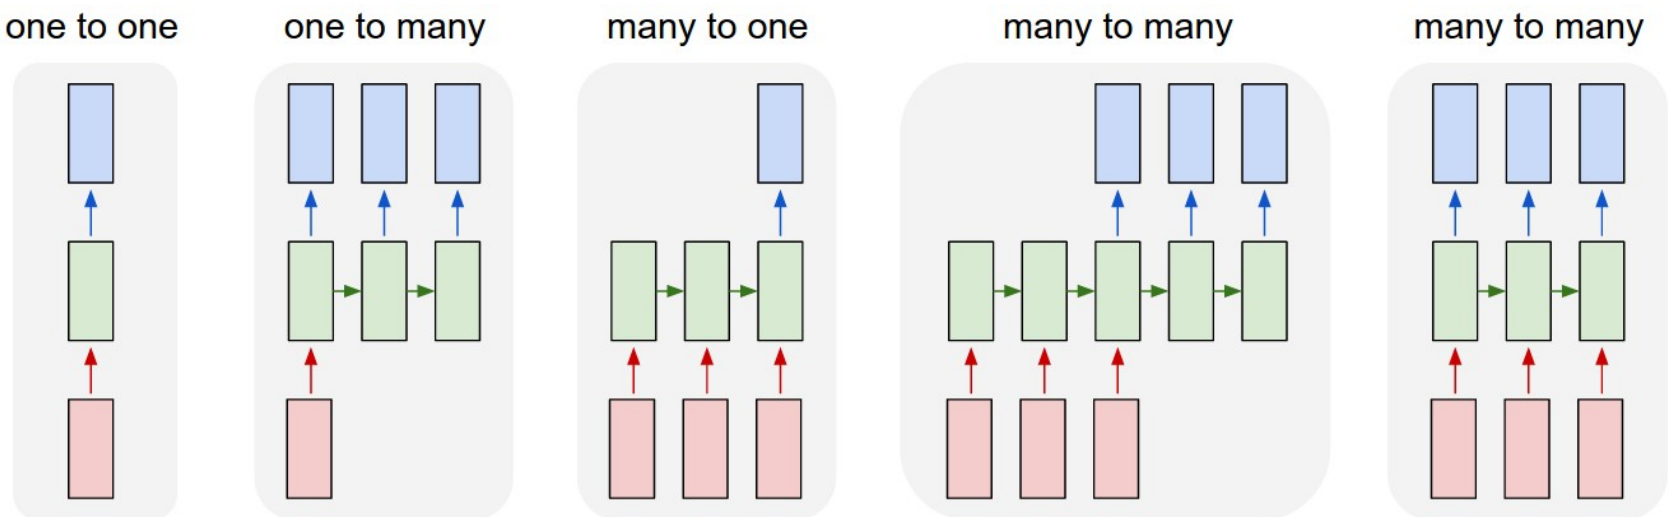

Taxonomia dos Problemas

- Iremos considerar somente as seguintes inferências, que de fato exigem memória de sequência.

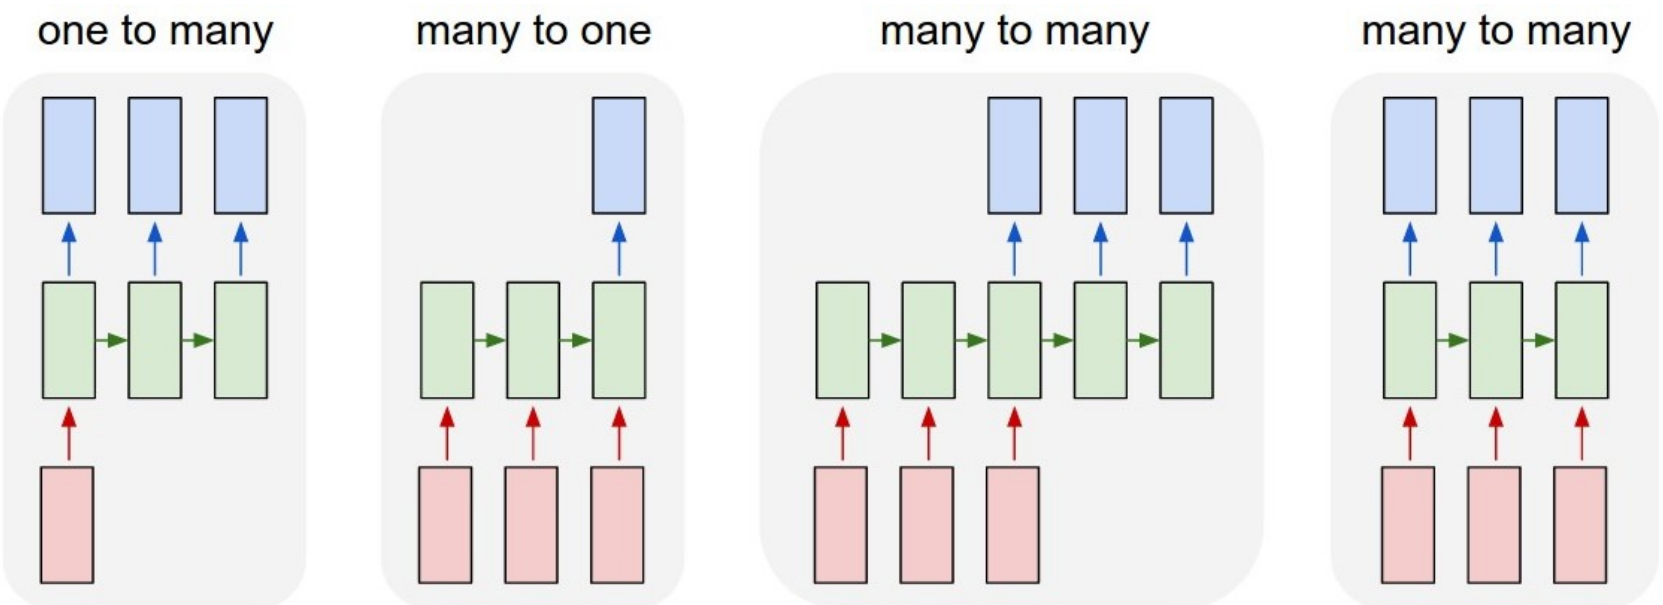

Taxonomia dos Problemas

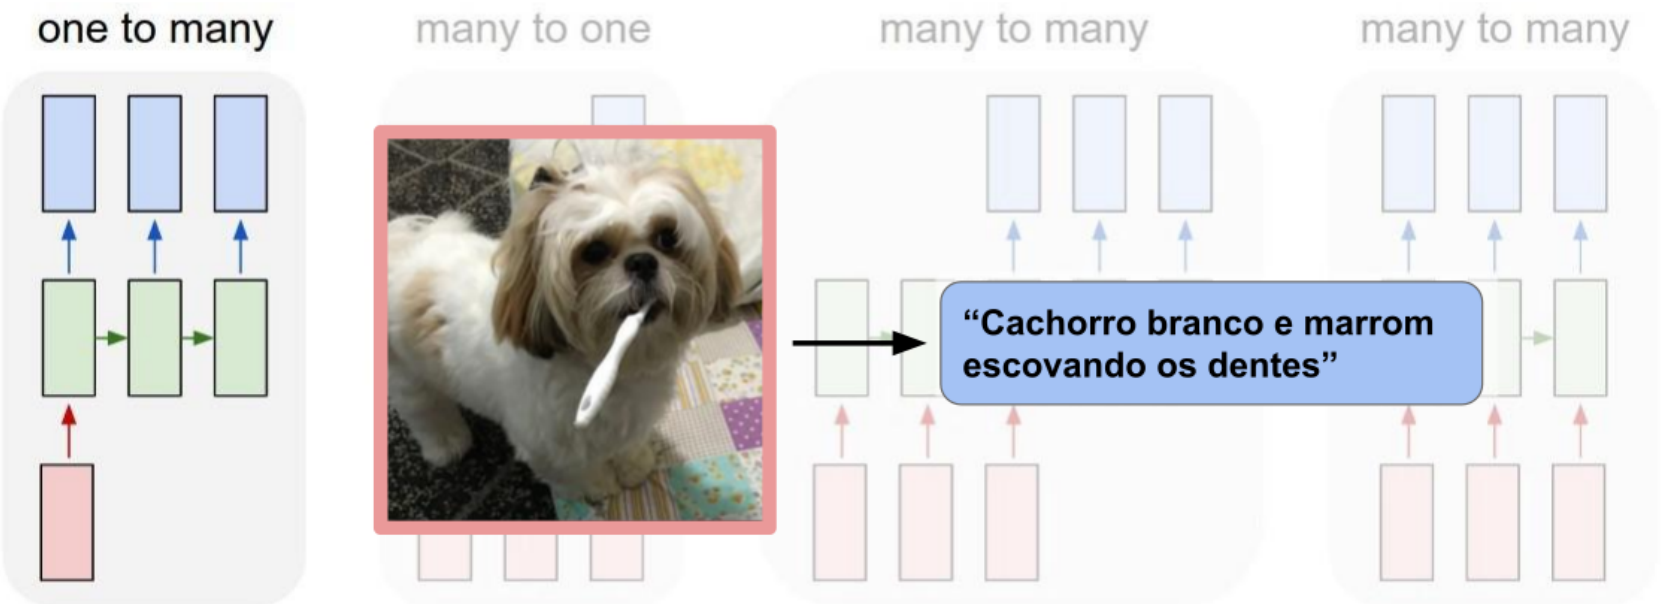

Figura: Exemplo de problema Um para Muitos: *Image Captioning*.

Taxonomia dos Problemas

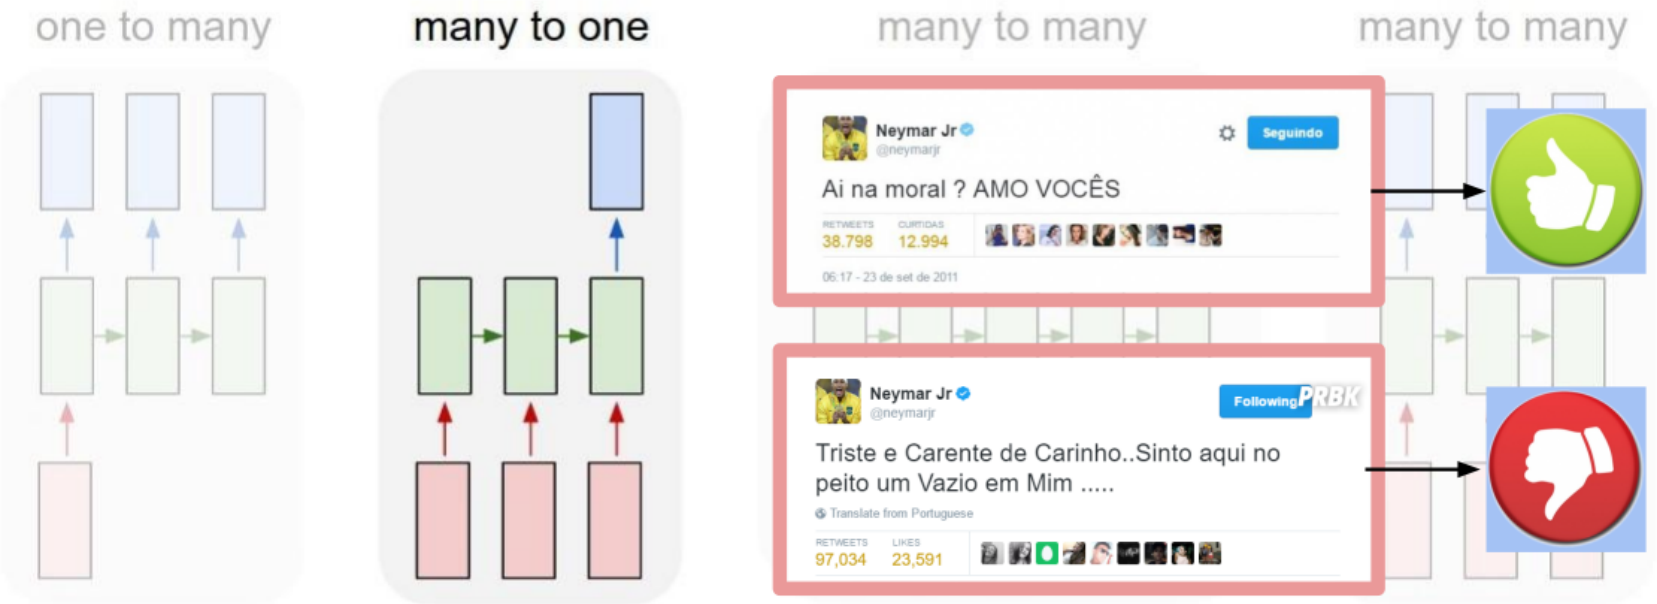

Figura: Exemplo de problema Muitos para Um: Análise de Sentimentos

Taxonomia dos Problemas

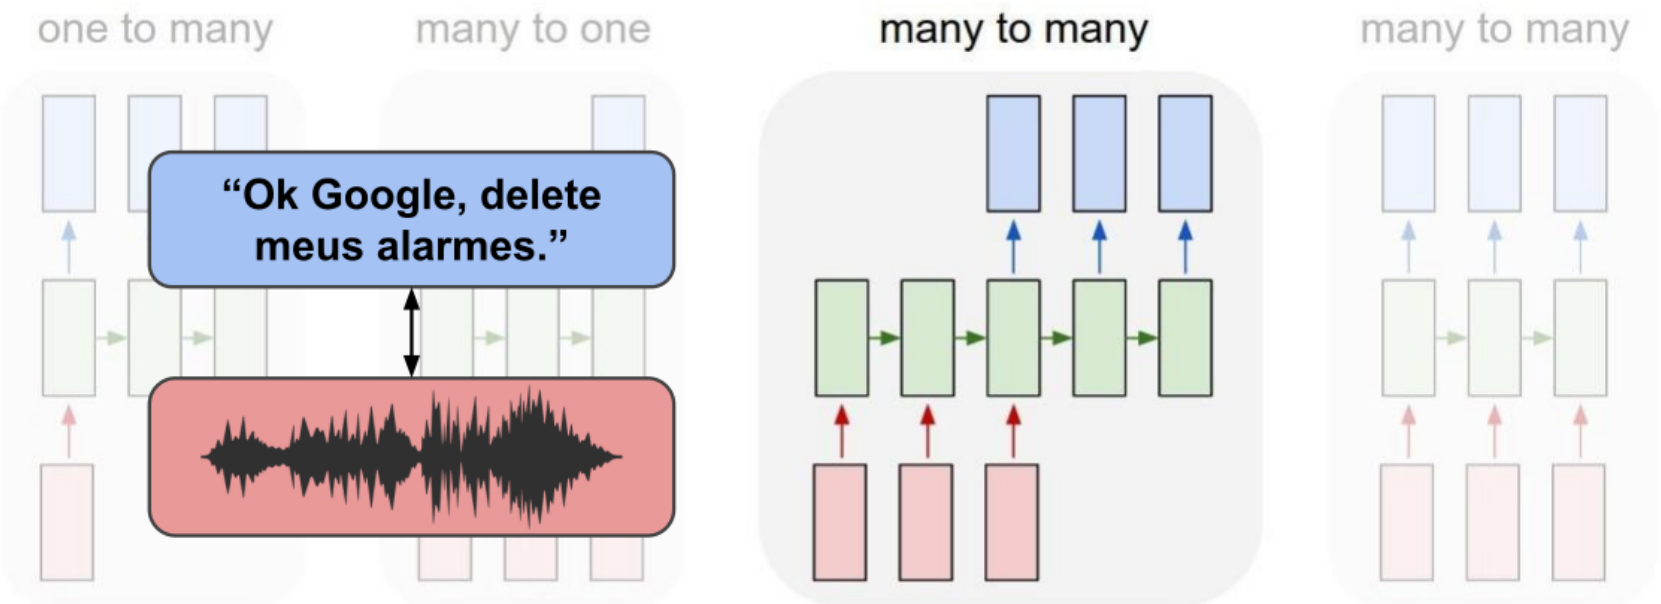

Figura: Exemplo de problema Muitos para Muitos: Voz para Texto

Taxonomia dos Problemas

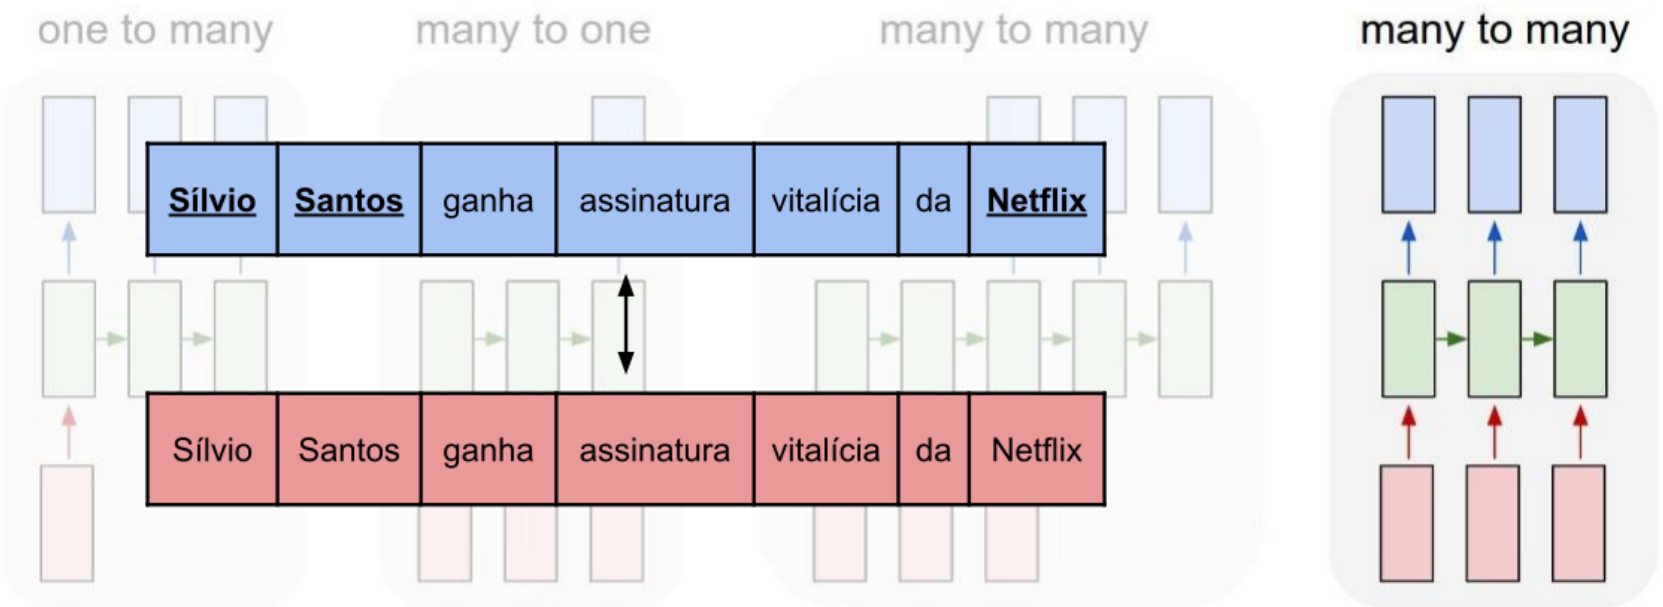

Figura: Exemplo de problema Muitos para Muitos sincronizado: Reconhecimento de entidade nomeada

Taxonomia dos Problemas

- O cálculo da loss também vai variar de acordo com o tipo do problema.

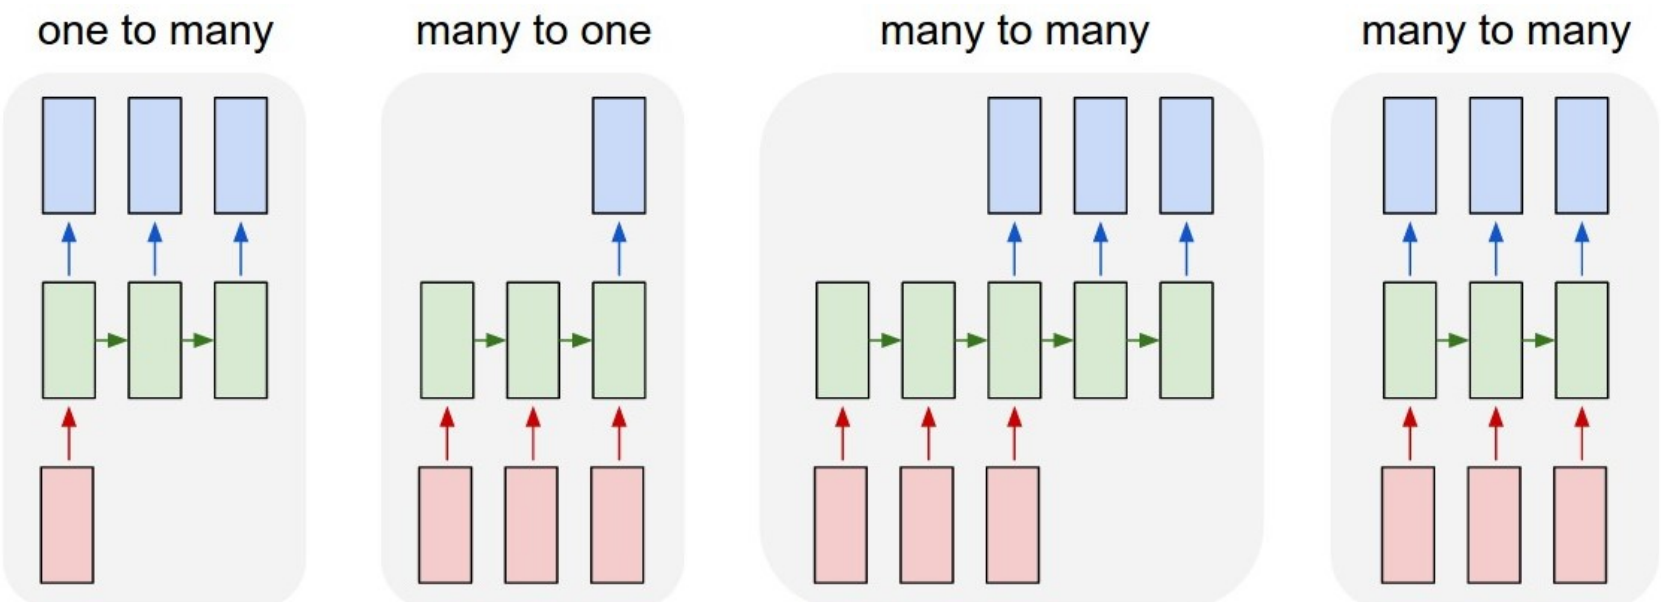

Taxonomia dos Problemas

- **Many-to-Many**: A função de perda é dada pelo acúmulo das perdas ao longo dos *timesteps*

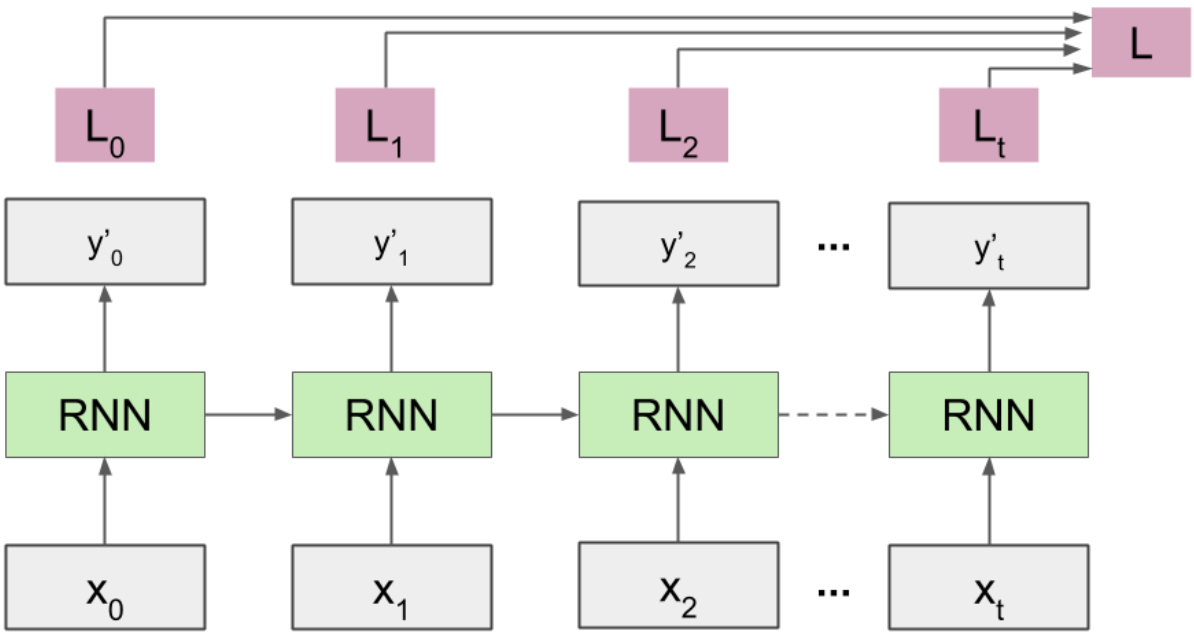

Taxonomia dos Problemas

- **Many-to-One**: Função de perda é dada apenas pelo último *timestep*

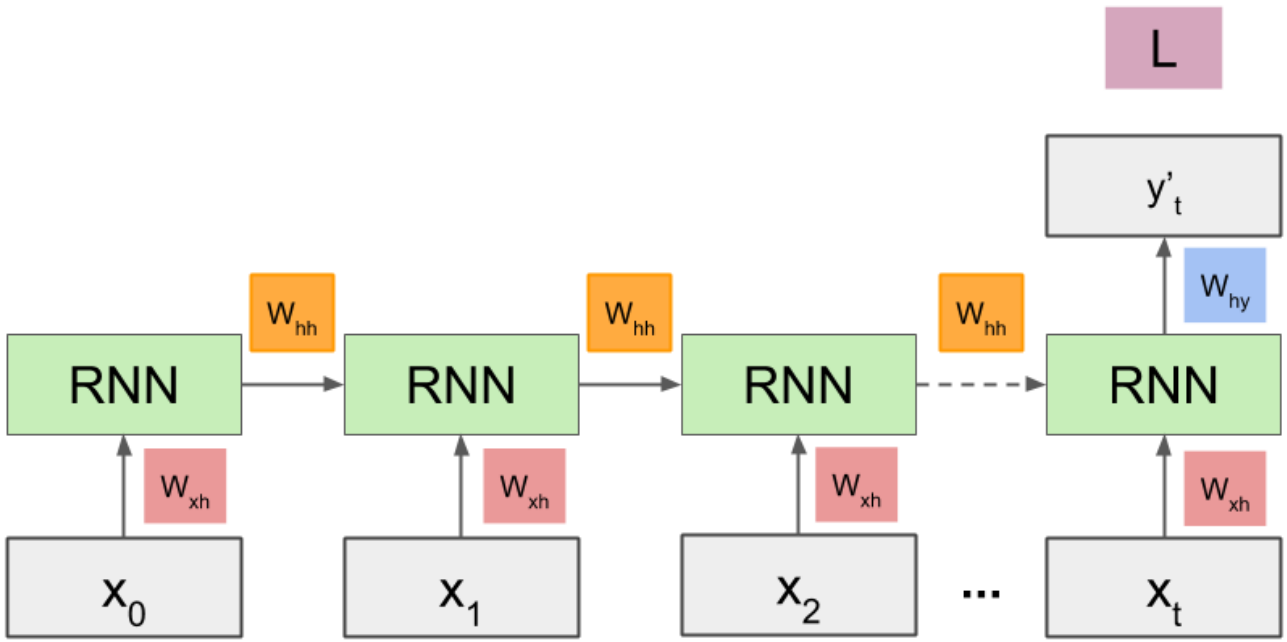

Taxonomia dos Problemas

- **One-to-Many**: A função de perda é dada pelo acúmulo das perdas ao longo dos *timesteps*

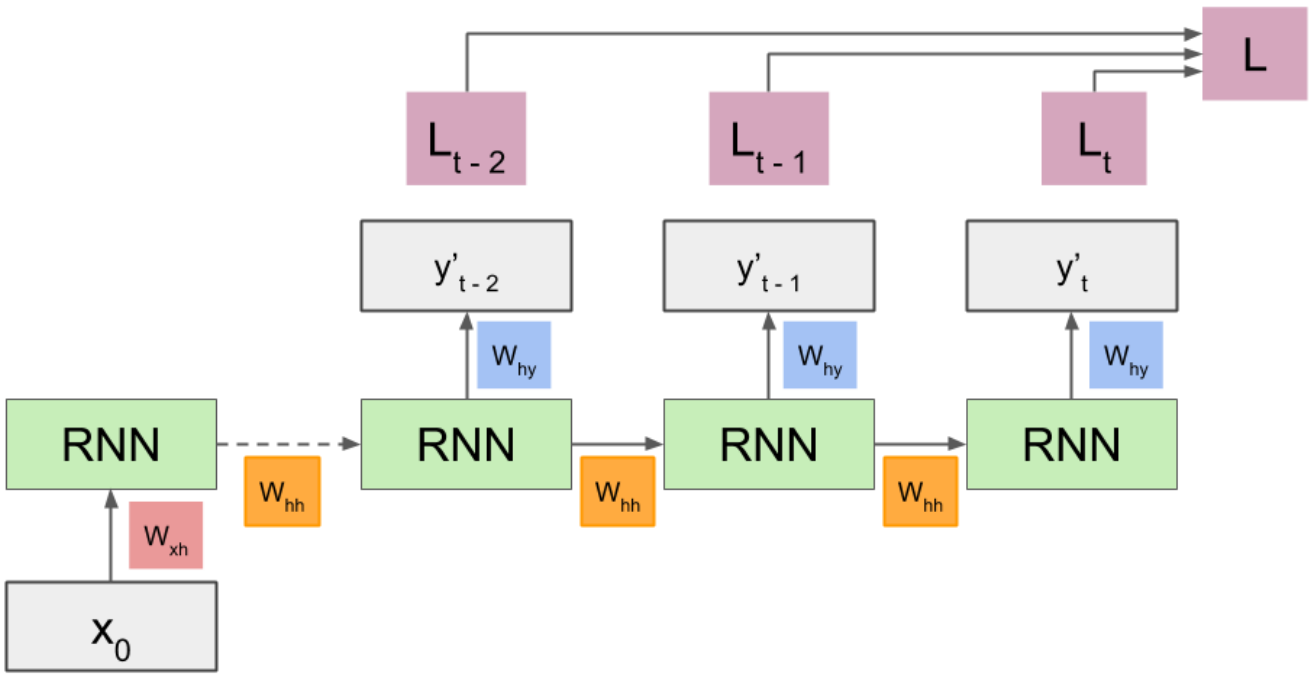

Atividade Prática

- Considere o seguinte problema:

  Dado um nome próprio de entrada, classifique esse nome de acordo com a nacionalidade.

  Gottfried $\rightarrow$ **Alemão**

- Como você modelaria a solução?

Atividade Prática

- Detalhes de implementação (atividade prática)
  - RNNCell (torch.nn.RNNCell)
    - input_size: Número de features da entrada
    - hidden_size: Número de features no *hidden state*
  - Linear (torch.nn.Linear)
    - in_features: Tamanho da entrada
    - out_features: Tamanho da saída
    - bias: [True, False]
  - Ativação LogSoftmax (torch.nn.LogSoftmax)
    - escolha arbitrária para o problema da atividade

Procedimento de Treinamento de RNNs

Atividade Prática

- Arquitetura
  - Camada RNNCell (input_size, hidden_size)
  - Camada Fully Connected (hidden_size, output_size)
  - Camada LogSoftmax
- Forward (Many-to-One)
  - # Inicialize o estado interno da RNN
  - # Loop Many-to-One. Itere na RNNCell caracter por caracter.
  - # Alimente as camadas Fully Connected e LogSoftmax com apenas o último estado recorrente.

Atividade Prática

Classificando nomes próprios

rnn_classification.py

Backpropagation Through Time

- A *backpropagation* nesse caso consiste em:
  - Desenrolar a rede para calcular o gradiente
  - Enrolar novamente para propagar
- Vamos considerar um problema Many-to-Many.

Backpropagation Through Time

- Na etapa de feed-forward computamos a perda em função do acúmulo das perdas intermediárias

$$\mathcal{L} = \sum_{t=0}^{T} \mathcal{L}_t(y'_t, y_t)$$

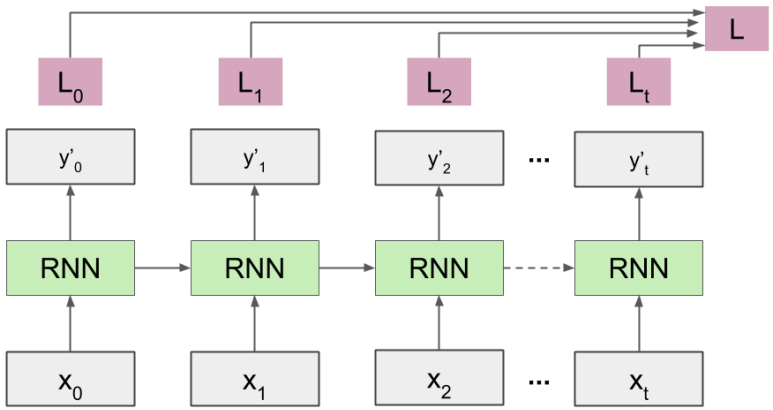

- Mas como fica o gradiente nessa confusão?

Backpropagation Through Time

- O gradiente final também é dado pelo acúmulo dos gradientes.
  - Em relação a W_{hy}

$$\sum_{t=0}^{T} \frac{\partial \mathcal{L}_t}{\partial W_{hy}}$$

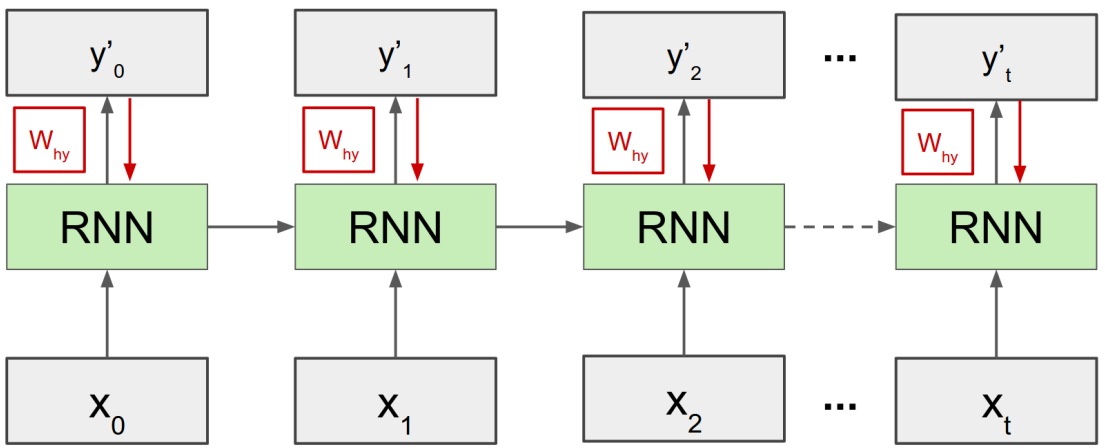

[1] Denny Britz. Recurrent Neural Network Tutorial, Part 4. 2018. http://www.wildml.com/2015/10/

Backpropagation Through Time

- Depois é só atualizar W_{hy} propagando o gradiente acumulado!
- Mas como calcular $\frac{\partial \mathcal{L}}{\partial W_{hh}}$ e $\frac{\partial \mathcal{L}}{\partial W_{xh}}$?

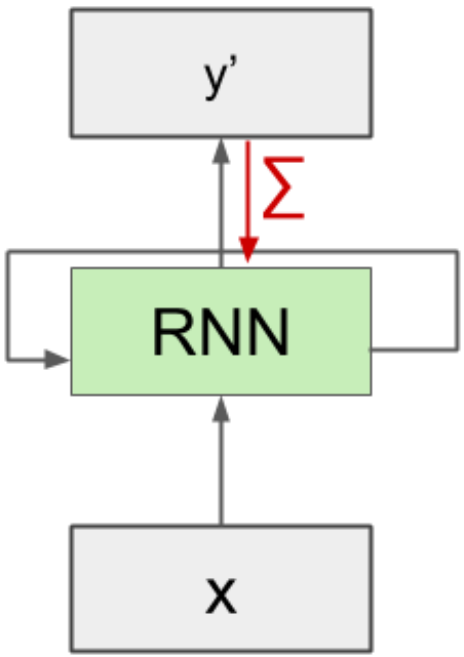

Backpropagation Through Time

- Como calcular $\frac{\partial \mathcal{L}_t}{\partial W_{hh}}$ **para um timestep**? [1]
- Precisamos aplicar a regra da cadeia desde o *timestep* atual até $t = 0$

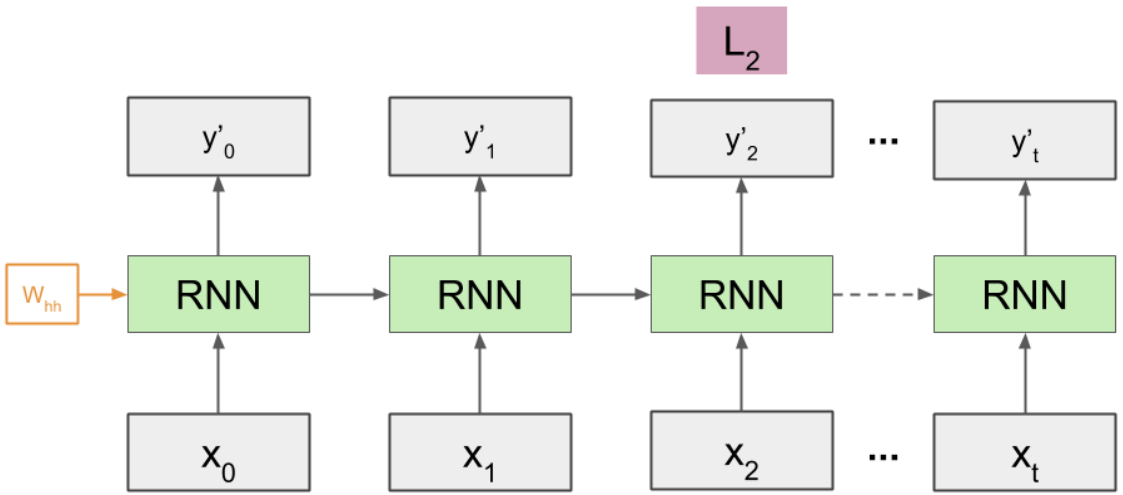

[1] Denny Britz. Recurrent Neural Network Tutorial, Part 4. 2018. http://www.wildml.com/2015/10/

Backpropagation Through Time

- Como calcular $\frac{\partial \mathcal{L}_t}{\partial W_{hh}}$? [1]
- Precisamos aplicar a regra da cadeia desde o *timestep* atual até $t = 0$

$$\frac{\partial \mathcal{L}_t}{\partial W_{hh}} = \sum_{k=0}^{t} \frac{\partial \mathcal{L}_t}{\partial y'_t} \frac{\partial y'_t}{\partial h_t} \left(\prod_{j=k+1}^{t} \frac{\partial h_j}{\partial h_{j-1}} \right) \frac{\partial h_k}{\partial W_{hh}}$$

- Repetimos o mesmo processo para todos os timesteps, acumulando os resultados

$$\sum_{t=0}^{T} \frac{\partial \mathcal{L}_t}{\partial W_{hh}}$$

[1] Denny Britz. Recurrent Neural Network Tutorial, Part 4. 2018. http://www.wildml.com/2015/10/

Backpropagation Through Time

- O mesmo vale para W_{xh} [1]
- Precisamos aplicar a regra da cadeia desde o *timestep* atual até $t = 0$

$$\frac{\partial \mathcal{L}_t}{\partial W_{xh}} = \sum_{k=0}^{t} \frac{\partial \mathcal{L}_t}{\partial y'_t} \frac{\partial y'_t}{\partial h_t} \left(\prod_{j=k+1}^{t} \frac{\partial h_j}{\partial h_{j-1}} \right) \frac{\partial h_k}{\partial W_{xh}}$$

- Repetimos o mesmo processo para todos os timesteps, acumulando os resultados

$$\sum_{t=0}^{T} \frac{\partial \mathcal{L}_t}{\partial W_{xh}}$$

[1] Denny Britz. Recurrent Neural Network Tutorial, Part 4. 2018. http://www.wildml.com/2015/10/

Backpropagation Through Time

- Depois é só atualizar os pesos propagando os gradientes acumulados!

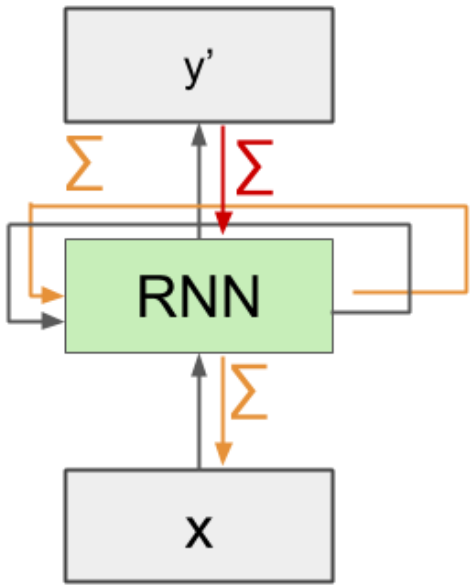

Vanishing / Exploding Gradient

- Relembrando:
  - **vanishing gradient**: gradiente tende a 0
  - **exploding gradient**: gradiente tende a infinito
- É um problema que se intensifica nas redes recorrentes
- Dependências de longo prazo exigem longas sequências
  - Como consequência, o estado das iterações mais antigas não contribuem para o aprendizado (em caso de vanishing)

Agenda

Unidades Avançadas

- Existem duas variações de redes recorrentes que se tornaram muito populares na literatura:
  - GRU - Gated Recurrent Unit
  - LSTM - Long Short-Term Memory
- São capazes de aprender dependências de longo prazo
- Evitam o problema de *vanishing* / *exploding gradient*
- Seu estado interno é reguladado por um conjunto de "*gates*"

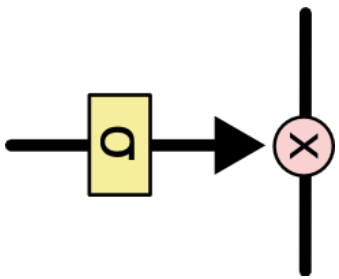

  - Literalmente um portão que decide quanto da informação pode passar.

GRU - Gated Recurrent Unit

- É composta por dois *gates*
  - Update Gate z_t
  - Reset Gate r_t
- Possui uma memória interna h'_t além da já existente h_t
- Para simplificar, os termos de bias foram omitidos
  - Sempre que ver expressos do tipo $(Wh + Ux)$, há um termo de bias que foi omitido, ou seja, o correto seria $(Wh + Ux + b)$

GRU - Gated Recurrent Unit [2]

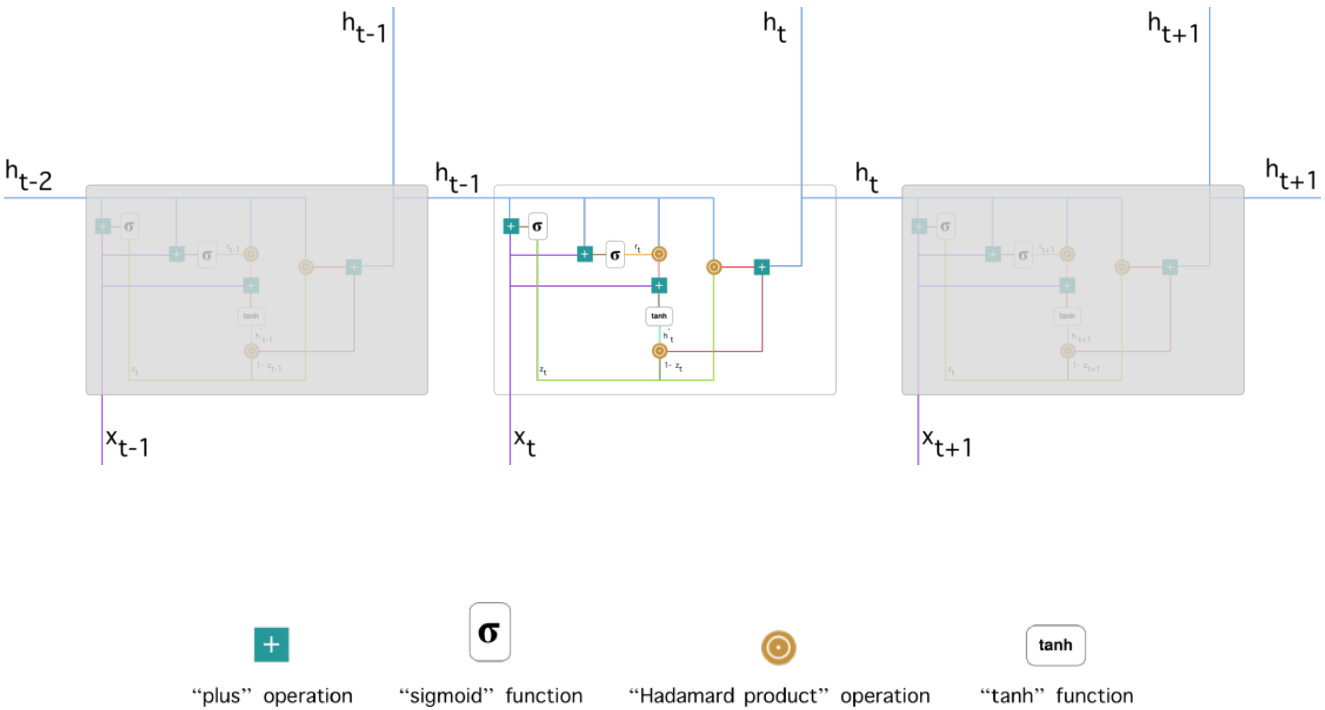

[2] https://towardsdatascience.com/understanding-gru-networks-2ef37df6c9be

GRU Gates

Update Gate (z_t)

- $z_t = \sigma(W^{(z)}x_t + U^{(z)}h_{t-1})$
- Combina o novo input x_t e o estado anterior h_{t-1}, com matrizes de peso próprias $W^{(z)}$ e $U^{(z)}$

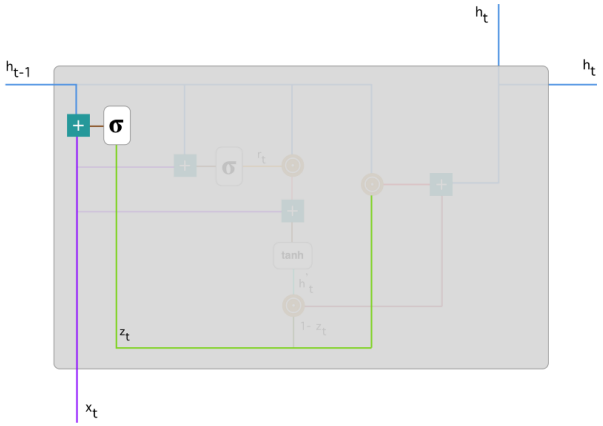

$$z_t = \sigma(W^{(z)}x_t + U^{(z)}h_{t-1})$$

GRU Gates

Reset Gate (r_t)

- $r_t = \sigma(W^{(r)} x_t + U^{(r)} h_{t-1})$
- Combina o novo input x_t e o estado anterior h_{t-1}, com matrizes de peso próprias $W^{(r)}$ e $U^{(r)}$

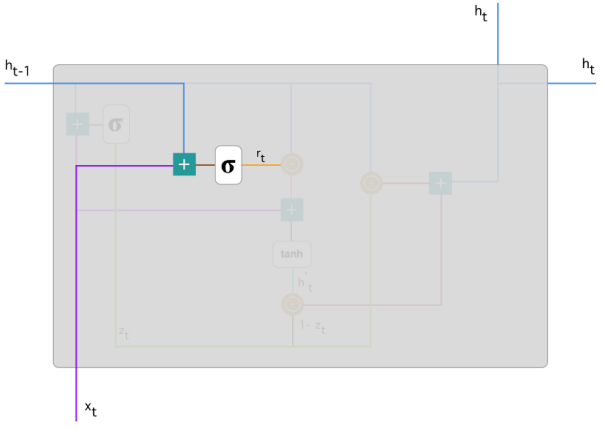

$$r_t = \sigma(W^{(r)} x_t + U^{(r)} h_{t-1})$$

GRU Gates

Memória interna (h'_t)

- $h'_t = tanh(Wx_t + \mathbf{r_t} \odot Uh_{t-1})$
- Aplica o **reset gate** sobre a informação do passado.

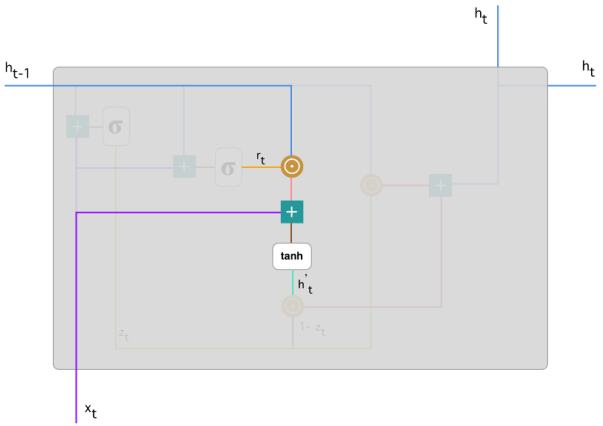

$$h_t^{'} = \tanh(Wx_t + r_t \odot Uh_{t-1})$$

- Se a unidade de reset é próxima de 0, o estado de memória anterior é ignorado e apenas a informação da nova entrada é considerada
- Unidades com dependências de curto prazo muitas vezes tem reset gates muito ativos

GRU Gates

Hidden state (h_t)

- $h_t = z_t \odot h_{t-1} + (1 - z) \odot h'_t$
- Aplica o **update gate** sobre a informação do passado e a memória interna

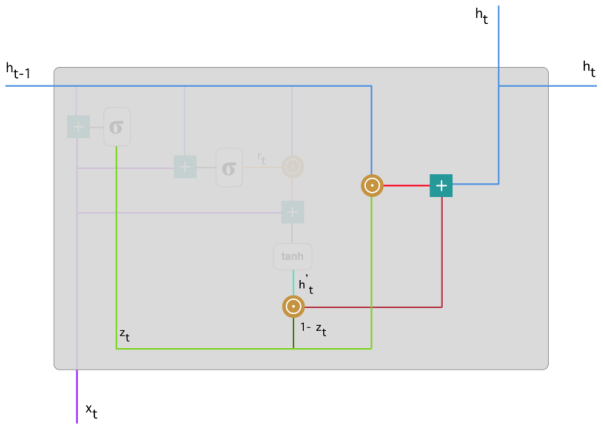

$$h_t = z_t \odot h_{t-1} + (1 - z_t) \odot h'_t$$

- O update gate controla o quanto do estado anterior é importante nesse momento.
- Unidades com dependências de longo prazo tem update gates ativos

GRUCell no Pytorch

- GRUCell (torch.nn.RNNCell)
  - input_size
  - hidden_size
  - bias
- A utilização é essencialmente a mesma que a RNNCell

In [ ]:
```
class GRU():
    def init(self, input_size, hidden_size):
        self.rnn = torch.nn.GRUCell(input_size, hidden_size)

    def forward(input_data):
        # Set initial hidden and cell states
        self.hidden = Variable(torch.zeros(batch_size, hidden_size))

        for x in input_data:
            self.hidden = self.rnn(x, self.hidden)
```

- Com a diferença que o resultado costuma ser melhor!

LSTM - Long Short-Term Memory

- É composta por três *gates*
  - Forget Gate f_t
  - Input Gate i_t
  - Output Gate o_t
- Possui um estado interno (*cell state* C_t) atualizado de maneira mais estável
- Rede recorrente mais popular atualmente na literatura

LSTM - Long Short-Term Memory [3]

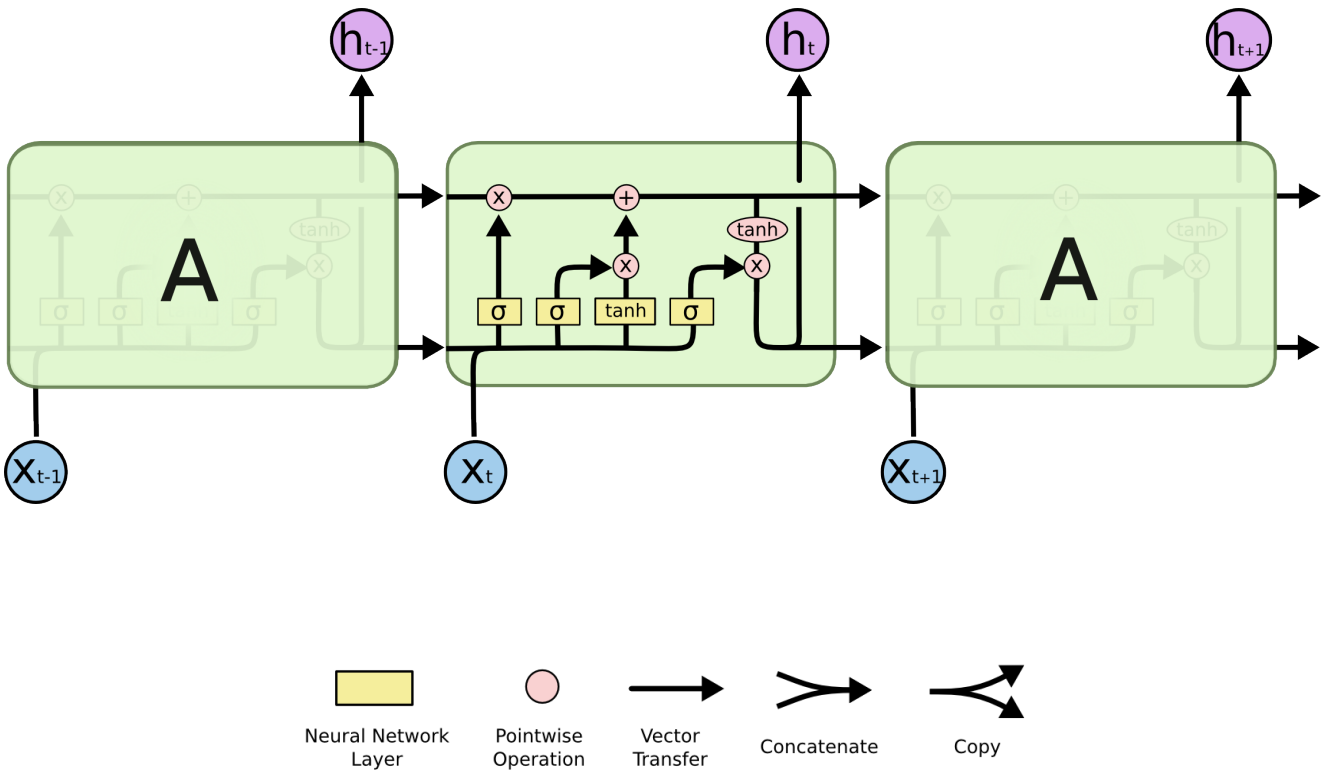

[3] http://colah.github.io/posts/2015-08-Understanding-LSTMs/

LSTM Gates

Forget Gate (f_t)

- $f_t = \sigma(W^{(f)} x_t + U^{(f)} h_{t-1})$
- Combina o novo input x_t e o estado anterior h_{t-1}, com matrizes de peso próprias $W^{(f)}$ e $U^{(f)}$

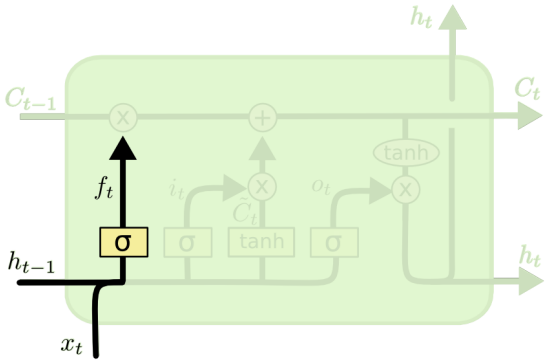

$$f_t = \sigma\left(W_f \cdot [h_{t-1}, x_t] \; + \; b_f\right)$$

LSTM Gates

Input Gate

- $i_t = \sigma(W^{(i)} x_t + U^{(i)} h_{t-1})$
- Combina x_t e h_{t-1}, com matrizes de peso próprias $W^{(i)}$ e $U^{(i)}$

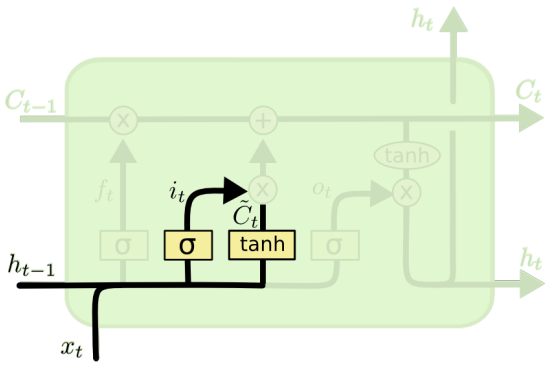

$$i_t = \sigma\left(W_i \cdot [h_{t-1}, x_t] \; + \; b_i\right)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] \; + \; b_C)$$

Cell State (candidatos)

- $C'_t = tanh(W^{(C)} x_t + U^{(C)} h_{t-1})$

LSTM Gates

Cell State (C_t)

- $C_t = f_t \odot C_{t-1} + i_t \odot C'_t$
- Aplica o **forget gate** no estado da célula do passado
- Aplica o **input gate** nos valores candidatos

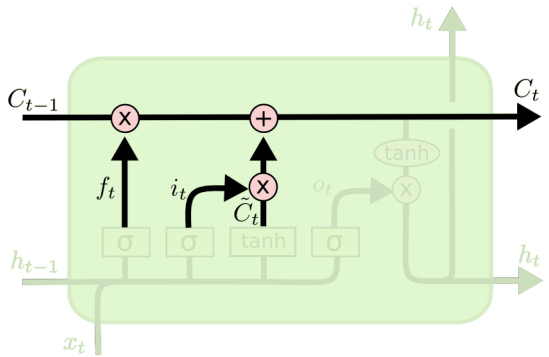

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$

- Dois gates independentes para definir quanto do passado deve ser jogado fora (f_t) e quanto do presente irá compor o estado interno (i_t).
- Fluxo de operações estável. Previne vanishing ou exploding gradient.

LSTM Gates

Output Gate (o_t)

- $o_t = \sigma(W^{(o)}x_t + U^{(o)}h_{t-1})$

Memória final (h_t)

- $h_t = o_t \odot tanh(C_t)$

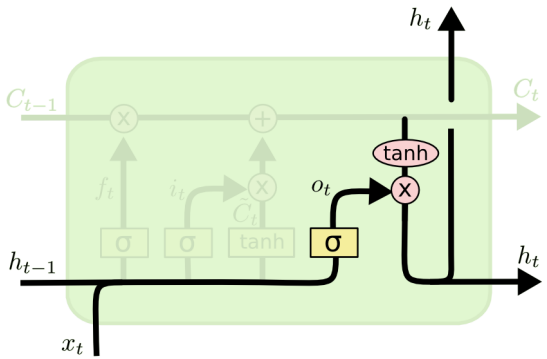

$$o_t = \sigma\left(W_o\left[h_{t-1}, x_t\right] + b_o\right)$$

$$h_t = o_t * \tanh\left(C_t\right)$$

- O output gate define quanto do estado interno C_t será passado para a próxima iteração.
- h_t é a feature temporal usada pelas próximas camadas.

LSTM

- Fluxo do gradiente na RNN tradicional

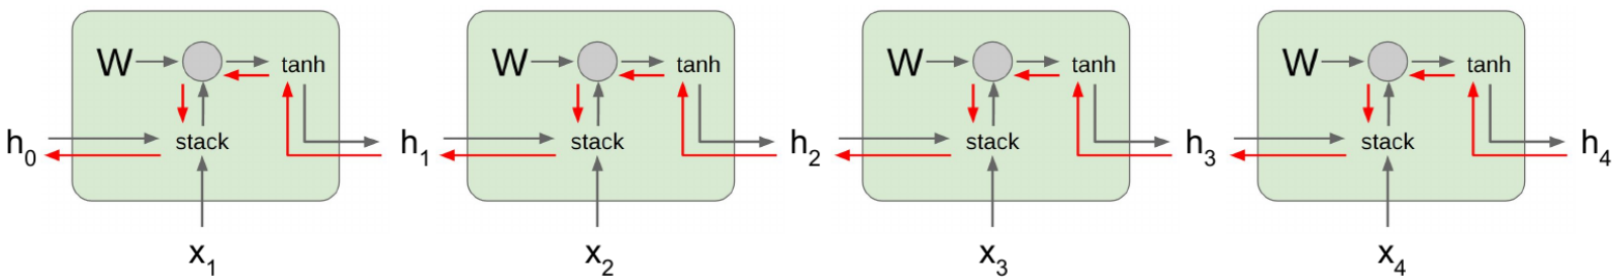

LSTM

- Fluxo do gradiente na LSTM

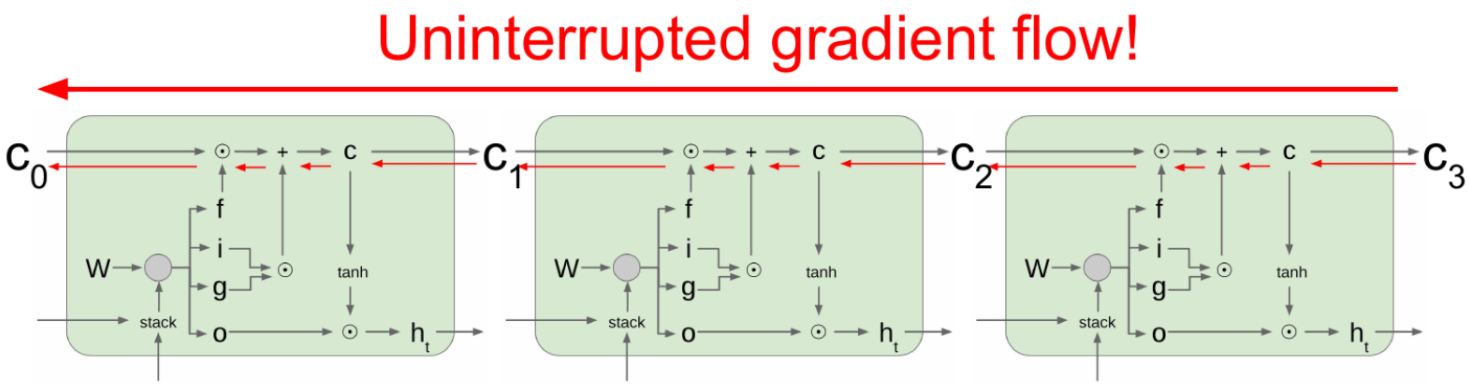

LSTM

- Fluxo do gradiente na LSTM
- Causa um efeito similar ao que aprendemos nas redes convolucionais residuais (Resnets)

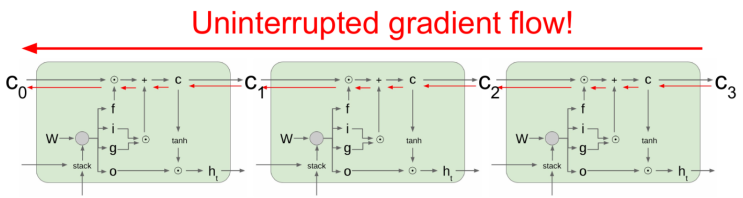

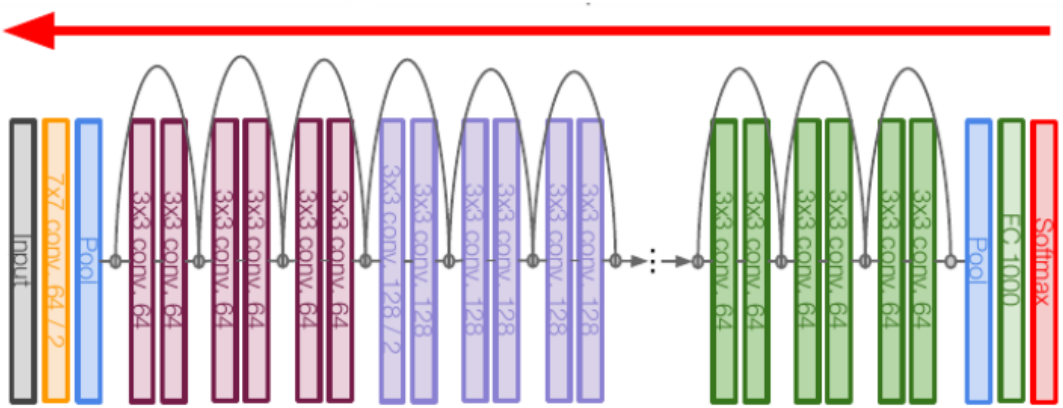

LSTMCell no Pytorch

- Detalhes de implementação (atividade prática)
  - LSTMCell (torch.nn.LSTMCell)
    - input_size
    - hidden_size
    - bias
  - Um parâmetro a mais para controlar: Cell State

In [ ]:
```
class LSTM():
    def init(input_size, hidden_size):
        self.rnn = torch.nn.LSTMCell(input_size, hidden_size)

    def forward(input_data):
        # Set initial hidden and cell states
        self.hidden     = Variable(torch.zeros(batch_size, hidden_size))
        self.cell_state = Variable(torch.zeros(batch_size, hidden_size))

        for x in input_data:
            self.hidden, self.cell_state = self.lstm(x, (self.hidden, self.cell_state))
            output = self.linear(self.hidden)
```

GRU vs LSTM

- LSTM
  - Mais parâmetros
  - Maior custo computacional
  - Treino mais difícil
  - Maior capacidade
- GRU
  - Menos parâmetros
  - Menor custo computacional
  - Treino mais fácil
  - Desempenho semelhante à LSTM na maioria das tarefas.

Multilayers em Pytorch

- Diferente das unidades **Cell*, o Pytorch oferece outro tipo de camada
  - RNN (torch.nn.RNN)
  - GRU (torch.nn.GRU)
  - LSTM (torch.nn.LSTM)

Multilayers em Pytorch

- O laço de repetição que implementamos até então é realizado internamente na camada
- É mais rápido que iterar nas unidades tipo **Cell*
- Retorna o estado interno para $t = seq\_len$ (hn, cn)

In [ ]:
```
def init(self, input_size, hidden_size):
    self.rnn = torch.nn.LSTMCell(input_size, hidden_size)

def forward(self, input_data):
        h, c = init_hidden()
        output = []
        for x in input_data:
            h, c = self.rnn(x, (h,c))
            output.append(h)
```

In [ ]:
```
def init(self, input_size, hidden_size):
    self.rnn = torch.nn.LSTM(input_size, hidden_size)

def forward(self, input_data):
        h0, c0 = init_hidden()
        output, (hn, cn) = self.rnn(input_data, (h0,c0))
```

Demo

Multilayers em PyTorch

RNN_multilayer.py

Multilayers em Pytorch

- RNN (torch.nn.RNN)
- GRU (torch.nn.GRU)
- LSTM (torch.nn.LSTM)

- Parâmetros
  - Input Size
  - Hidden Size
  - Bias
  - **Num Layers**
  - **Batch First**
  - **Dropout**
  - **Bidirectional**

Multilayers em Pytorch

- Num Layers: Número de camadas recorrentes
  - A segunda camada recebe inputs da primeira, a terceira recebe da segunda, e assim por diante.
- Batch First: marcador booleano
  - batch_first = **False**: input.size() = (seq_len, **batch_size**, input_size)
  - batch_first = **True**: input.size() = (**batch_size**, seq_len, input_size)

Multilayers em Pytorch

- Dropout: float
  - Introduz uma camada de Dropout depois de todas as camadas recorrentes, exceto a última
- Bidirectional: marcador booleano
  - Bidirectional = **True**

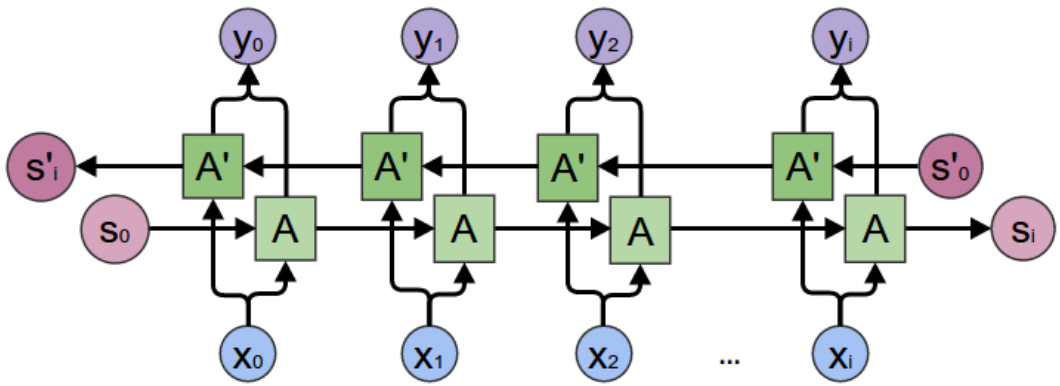

Multilayers em Pytorch

- Detalhes de implementação (atividade prática)
  - LSTM (torch.nn.LSTM)
    - input_size
    - hidden_size
    - num_layers
    - **batch_first**: True
  - Linear (torch.nn.Linear)
    - in_features: Tamanho da entrada
    - out_features: Tamanho da saída

Atividades Práticas

Previsão de Sequências

Forecast.py

Regressão MNIST

PixelGRU.py